ИТМО

Хранилища данных

Зоопарк систем вокруг IT специалиста

Виды данных:

- структурированные (XLSX, CSV)
- полуструктурированные (XML, JSON, YAML)
- неструктурированные (WAV, MP3, Ogg, MP4, WMV, JPEG, PNG)

Информационная система:

- системы обработки данных (СОД)
- системы анализа данных (САД)



Функции СППР

- ✓ Генерация возможных вариантов решений
- ✓ Осуществление оценки этих вариантов и выбор наилучшего
- ✓ Обеспечение постоянного обмена информацией между руководителями для согласования групповых решений
- ✓ Моделирование принимаемых решений
- ✓ Оценка соответствия выполнения принятых решений намеченным целям

Аналитические приложения

- ✓ Сфера детализированных данных
- ✓ Сфера агрегированных показателей
- ✓ Сфера закономерностей

Данные могут быть

- ✓Агрегированные
- ✓Исторические
- ✓Прогнозируемые

Характеристики СОД

Характеристика	Статический анализ	Динамический анализ
Типы вопросов	Сколько? Как? Когда?	Почему? Что будет если?
Время отклика	Не регламентируется	Секунды
Типичные операции	Регламентированный отчет, диаграмма	Последовательность интерактивных отчетов, диаграмм, экранных форм; динамическое изменение уровней агрегации и срезов данных
Уровень аналитических требований	Средний	Высокий
Тип экранных форм	В основном определенный заранее, регламентированный	Определяемый пользователем
Уровень агрегации данных	Детализированные и суммарные	В основном суммарные
Возраст данных	Исторические и текущие	Исторические, текущие и прогнозируемые
Типы запросов	В основном предсказуемые	Непредсказуемые, от случаю к случаю
Назначение	Работа с историческими и текущими данными, регламентированная аналитическая обработка и построение прогнозов	Работа с историческими, текущими и прогнозируемыми данными. Многопроходный анализ, моделирование

Характеристики данных

Характеристика	Оперативные - OLTP (On-Line Transactional Processing)	Аналитические - OLAP (On-Line Analytical Processing)
Частота обновления	Высокая частота, маленькими порциями	Малая частота, большими порциями
Источники данных	В основном внутренние	В основном внешние (по отношению к аналитической системе)
Возраст данных	Текущие (за период от нескольких месяцев до одного года)	В основном исторические (за период в несколько лет, десятки лет) и прогнозируемые
Уровень агрегации данных	Детализированные данные	В основном агрегированные данные

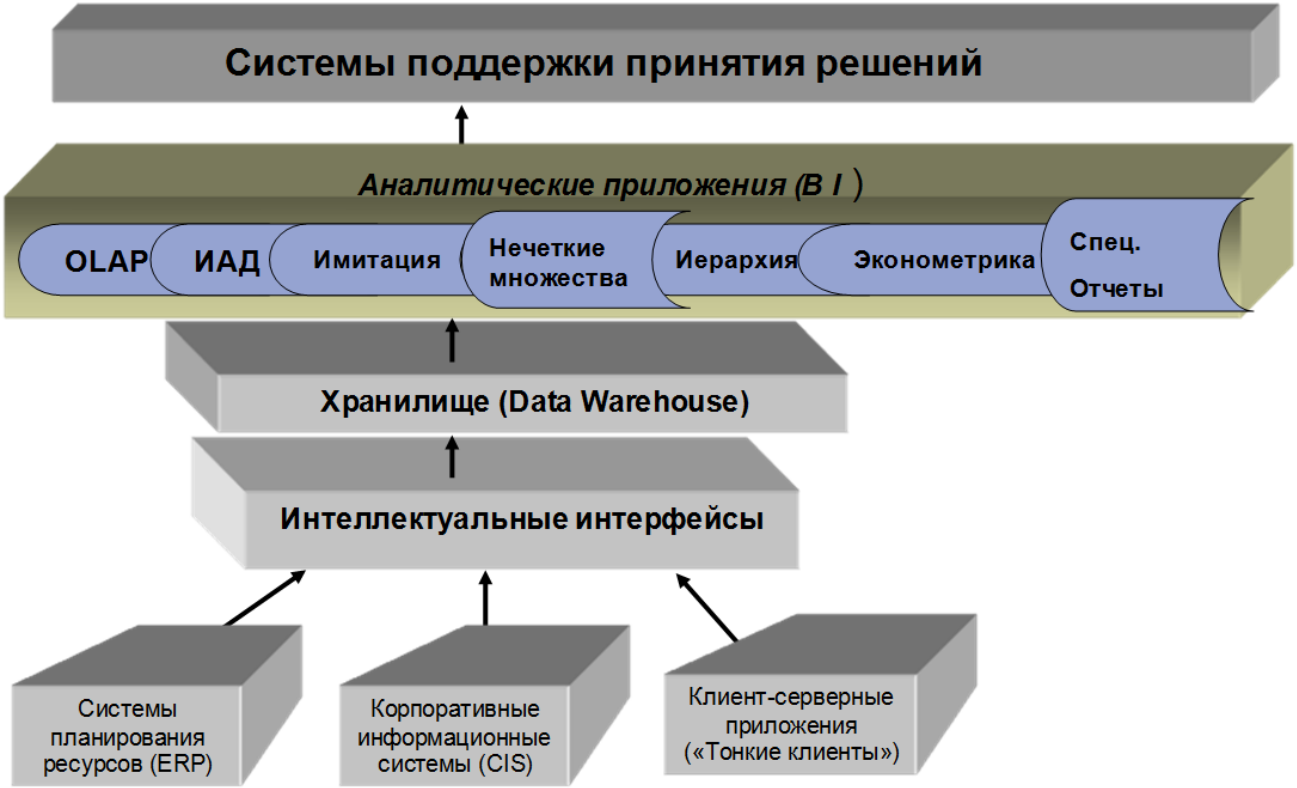
Требования к хранению данных в БД и ХД

Традиционные данные, хранимые в БД	Данные для принятия решений
Детализированы	Обобщены либо очищены
Точны в момент доступа	Представляют значения на указанное время
Могут корректироваться	Не корректируются, если введены в Хранилище
Требования к способам дальнейшей обработки выясняются заранее	Требования к способам дальнейшей обработки не имеют первостепенного значения
Чувствительны к производительности БД и поэтому предъявляют к ним жесткие требования	Мягкие требования к производительности БД

Требования к хранению данных в БД и ХД
(продолжение)

Обрабатывается один элемент данных за один запрос	Обрабатывается множество элементов данных за один запрос
Управляются транзакциями	Управляются аналитическими запросами
Ориентированы на приложения	Ориентированы на анализ
Высокая степень доступности	Относительная доступность
Контролируется целостность всех данных	Контролируется целостность подмножества данных
Данные не избыточны	Данные избыточны
Статическая структура, произвольное содержание	Гибкая структура
Массивы данных редко используются в процессе обработки	Массивы данных широко используются в процессе обработки
Поддерживают ежедневные операции	Поддерживают периодический анализ

Место хранилища в информационной системе



Архитектура СППР



Составляющие Хранилища Данных

- ✓предметная ориентированность;
- ✓интегрированность (целостность и внутренняя взаимосвязь);
- ✓временная привязка;
- ✓неразрушаемая совокупность данных.

Этапы заполнения ХД:

- ✓этап извлечения и преобразования;
- ✓этап очистки данных;
- ✓ этап загрузки;
- ✓ этап обновления;
- ✓управление метаданными.

Аналитические приложения

- ✓Построение отчетов (Reporting)
- ✓Выполнение нерегламентированных отчетов (Ad hoc query)
- ✓Многомерный анализ (OLAP)
- ✓Извлечение знаний (Data mining)

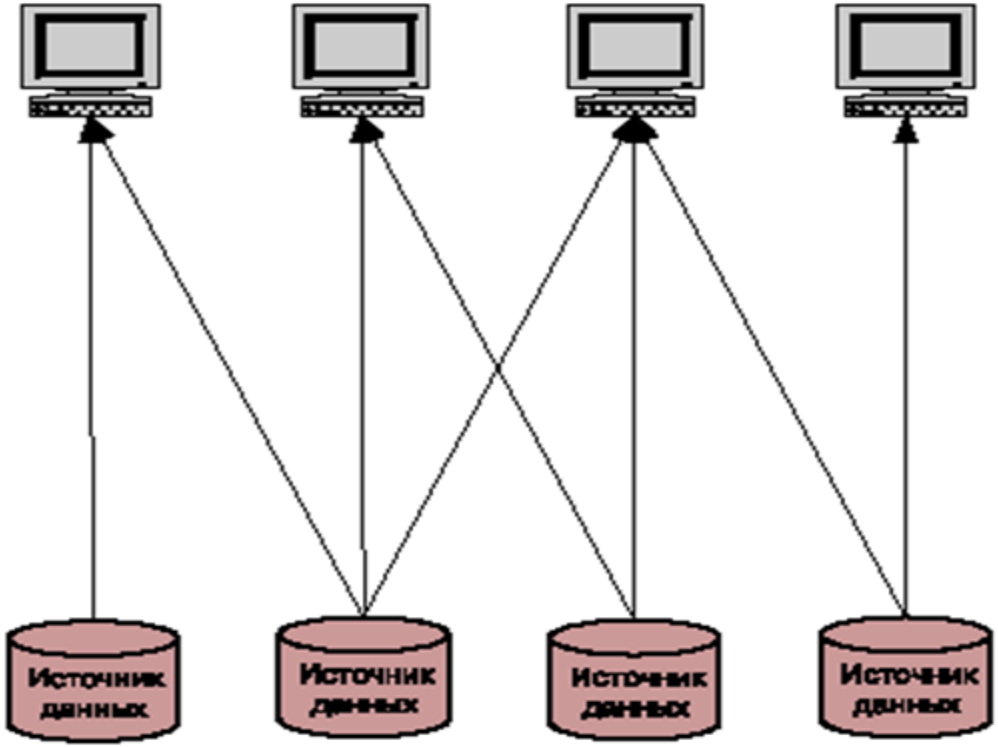
Типы корпоративных хранилищ данных

- ✓ Хранилище данных внутри компании
- ✓ Виртуальное хранилище данных
- ✓ Облачное хранилище данных

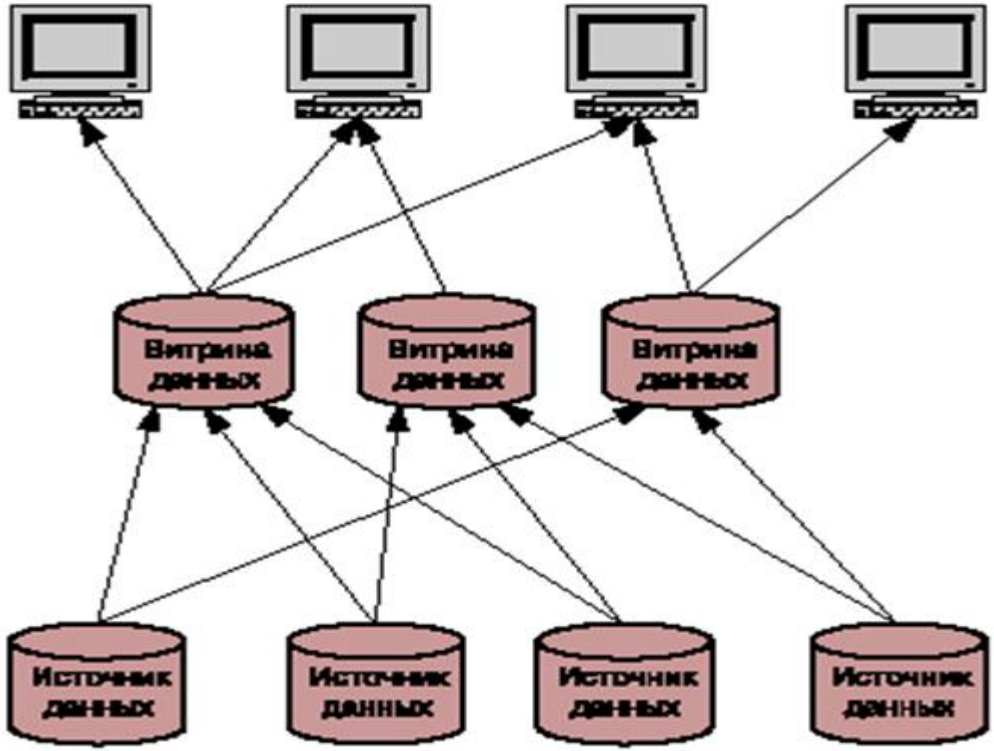
Варианты архитектур САД

- ✓ Функциональная СППР.
- ✓ Независимые витрины данных.
- ✓ Двухуровневое хранилище данных.
- ✓ Трехуровневое хранилище данных

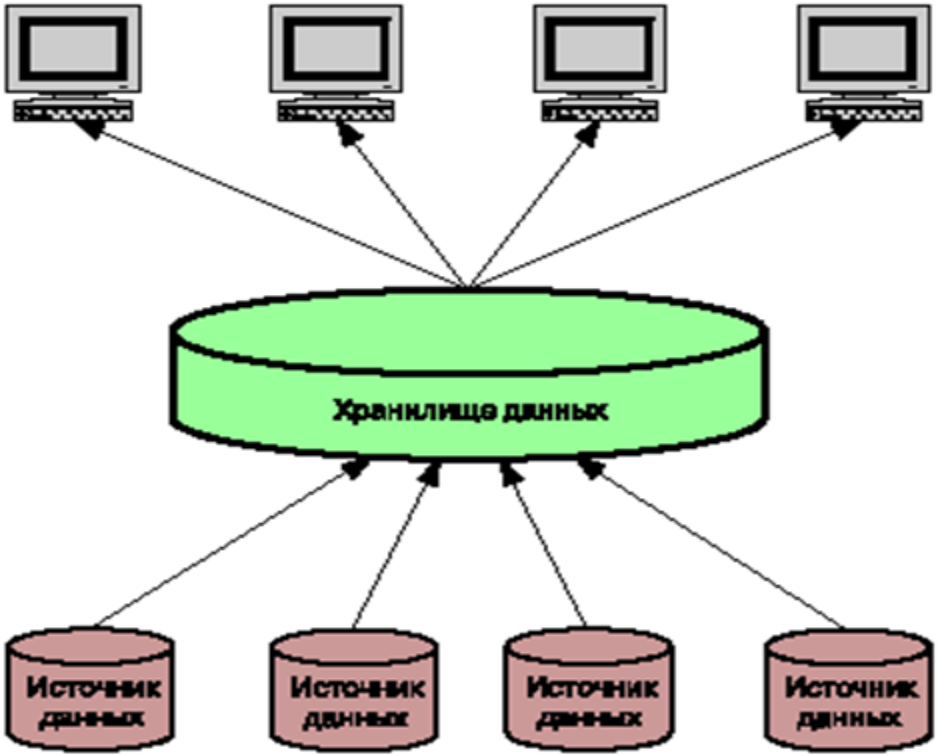
Функциональная СППР



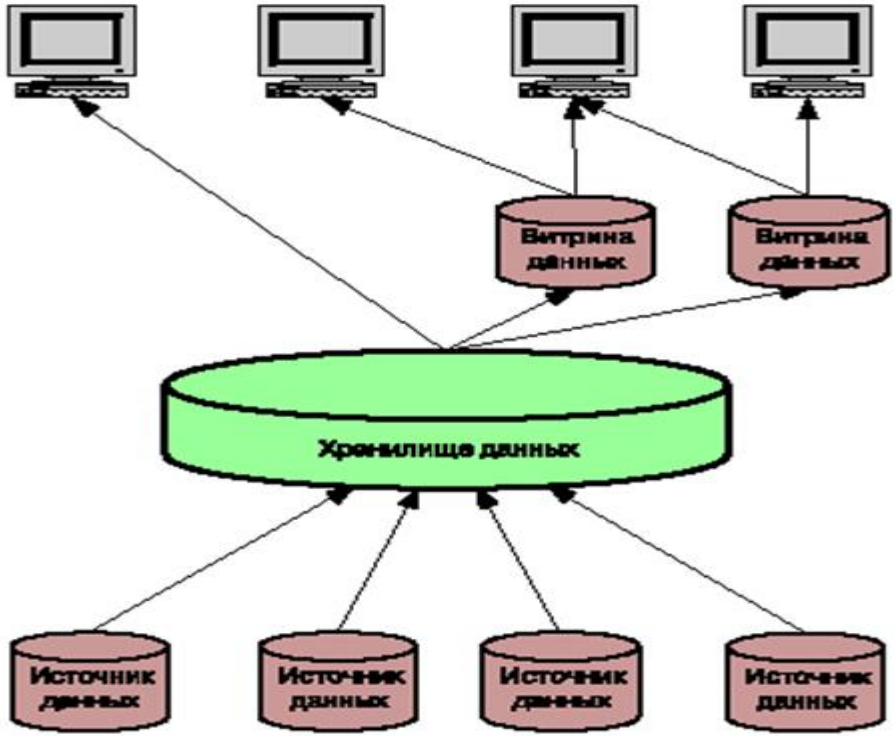
Независимые витрины данных



Двухуровневое ХД



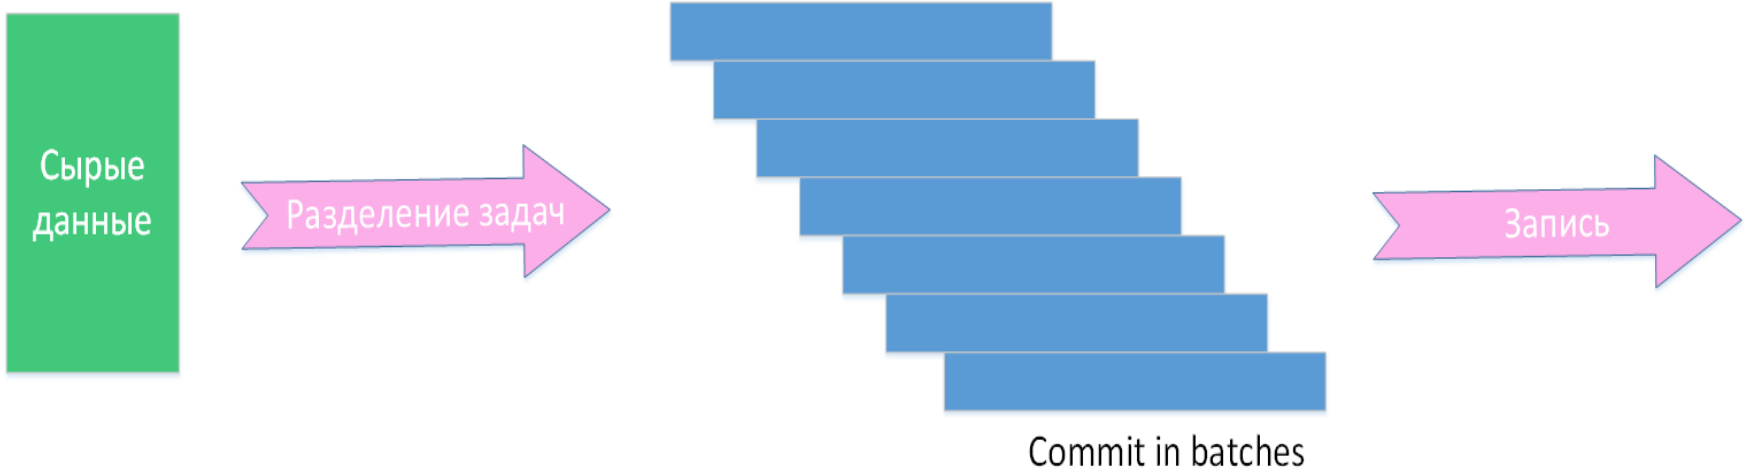
Трехуровневое ХД



Типы систем

- ✓*Сервисы (онлайновые системы)*
- ✓*Системы пакетной обработки (автономные системы).*
- ✓*Системы поточной обработки (системы почти реального времени).*

Традиционная архитектура пакетной обработки



Как составляются пакеты данных

- По времени создания.
- По типу данных.
- По источнику.
- По содержимому.
- Вручную по различным критериям

Архитектура

