ИТМО

Технологии хранения данных

Терминология и история

Data Warehouse - *предметно ориентированные, интегрированные, неизменчивые, поддерживающие хронологию наборы данных, организованные для целей поддержки управления” (*Б.Инмон*)*

Data Warehouse – это место, где люди могут получить доступ к своим данным (Р. Кимбалл)

Денормализованные, пространственные базы данных

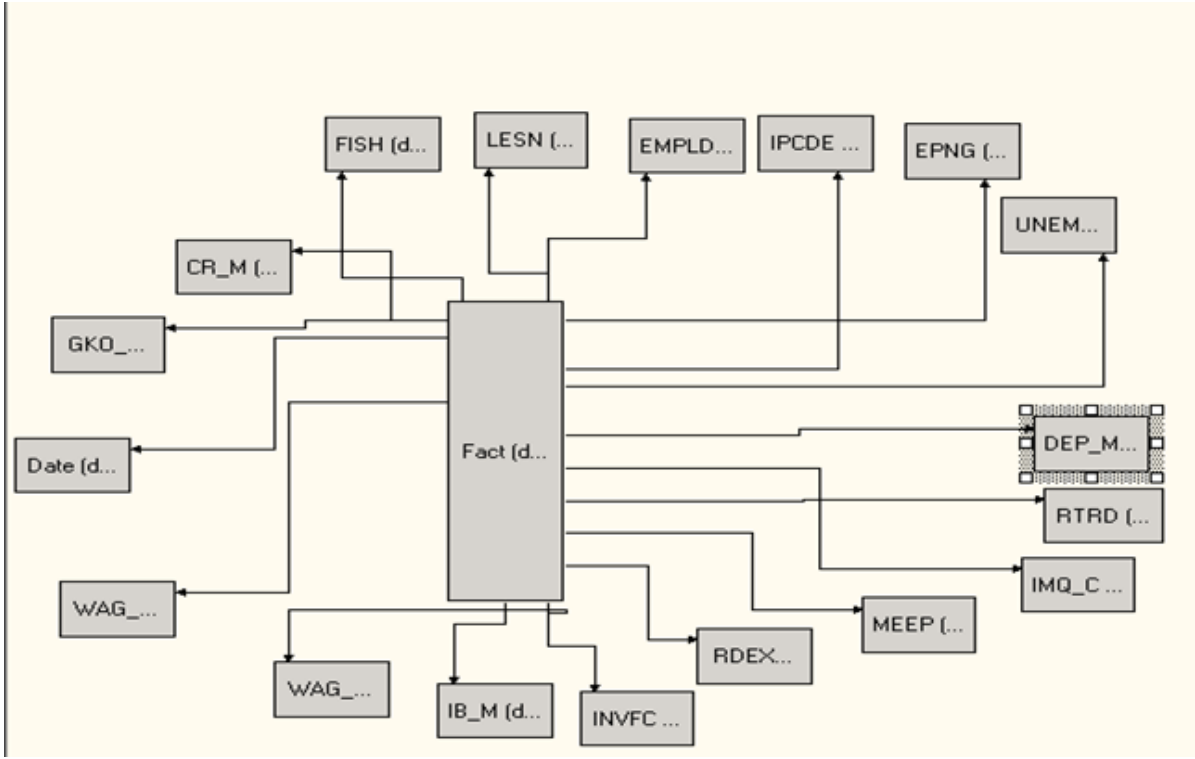
Методология Dimensional

Нормализация данных в реляционных СУБД приводит к созданию множества связанных между собой таблиц. В результате, выполнение сложных запросов неизбежно приводит к объединению многих таблиц, что существенно увеличивает время отклика.

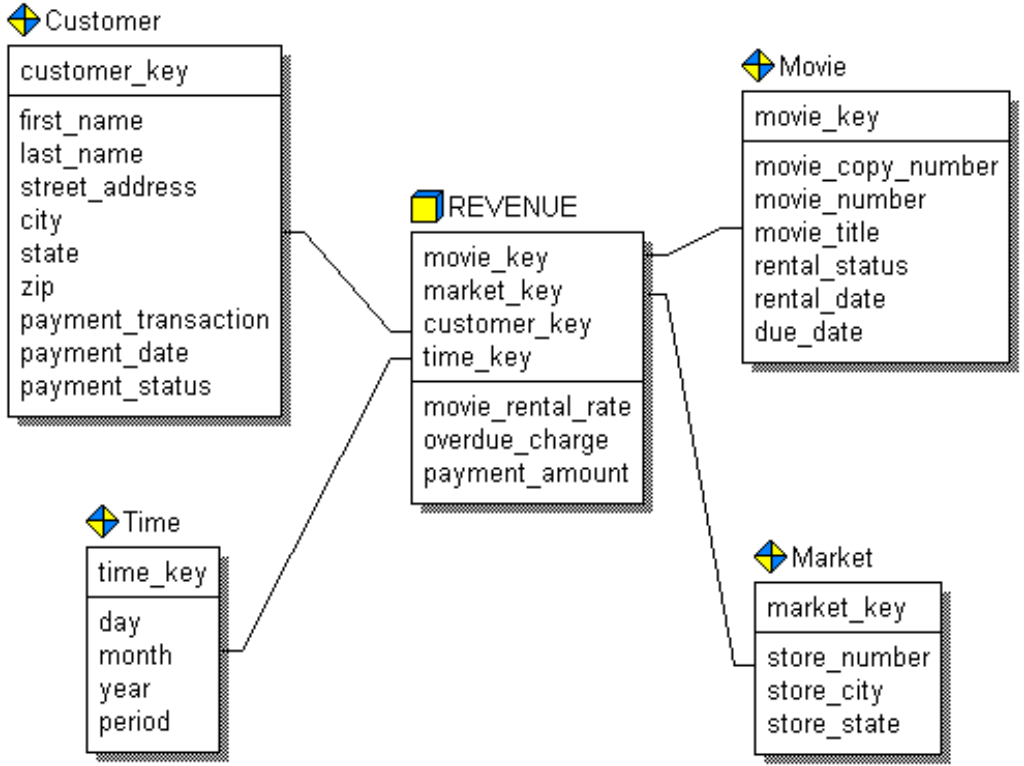
Создание хранилища данных подразумевает создание денормализованной структуры данных (допускается избыточность данных и возможность возникновения аномалий при манипулировании данными), ориентированной в первую очередь на высокую производительность при выполнении аналитических запросов.

Нормализация делает модель хранилища слишком сложной, затрудняет ее понимание и ухудшает эффективность выполнения запроса.

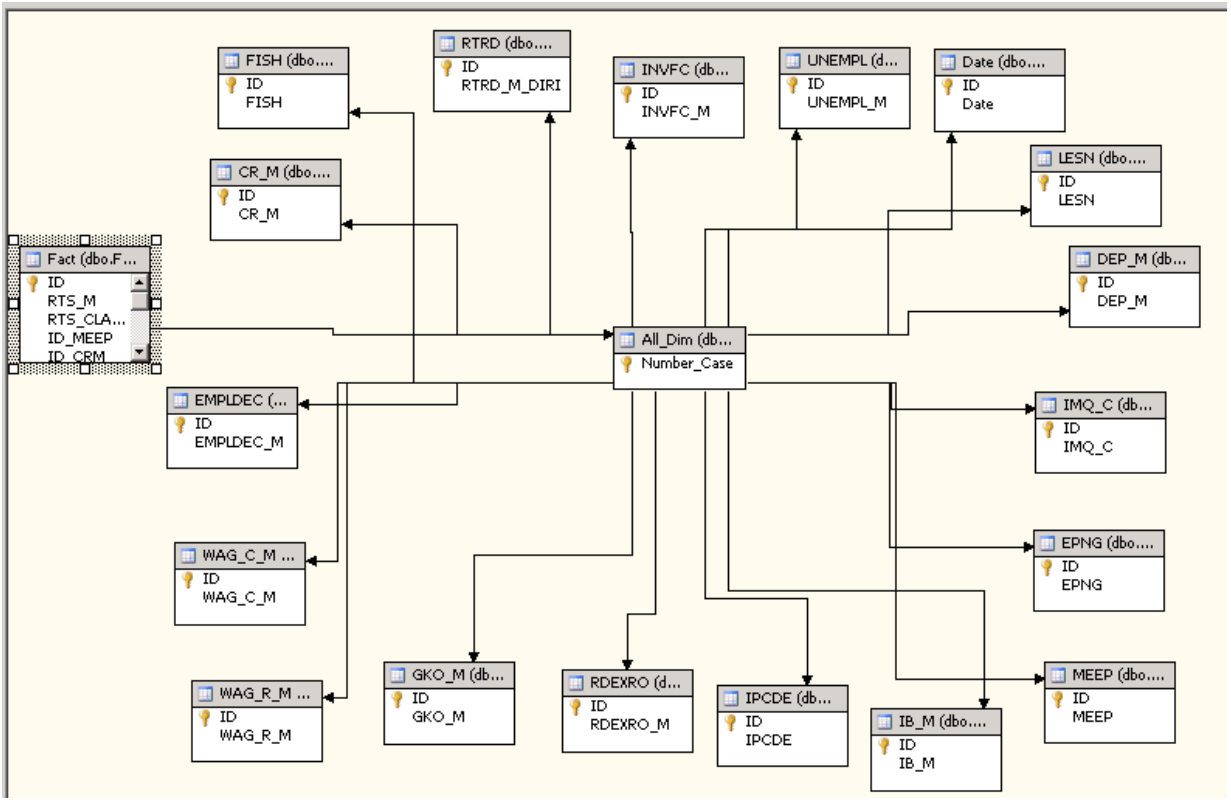
О схеме звезда



Звезда


Customer
customer_key
first_name
last_name
street_address
city
state
zip
payment_transaction
payment_date
payment_status
REVENUE
movie_key
market_key
customer_key
time_key
movie_rental_rate
overdue_charge
payment_amount
Movie
movie_key
movie_copy_number
movie_number
movie_title
rental_status
rental_date
due_date
Time
time_key
day
month
year
period
Market
market_key
store_number
store_city
store_state

О схеме снежинка



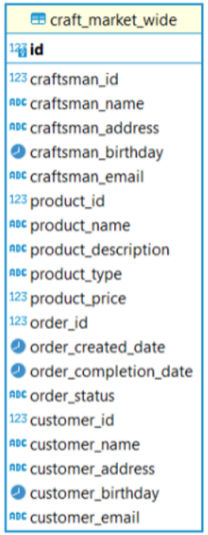
Правила хранения данных (Data Warehouse Rules)

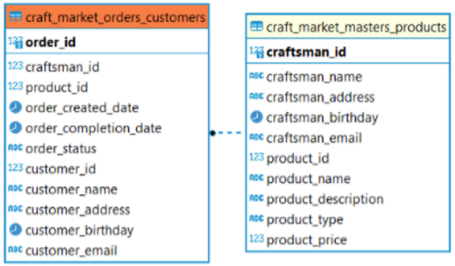
- обновление (Refresh)
- дополнение (Append)
- резервное копирование (Backup)
- восстановление (Recovery)
- архивирование (Archiving)
- очистка (Purge)

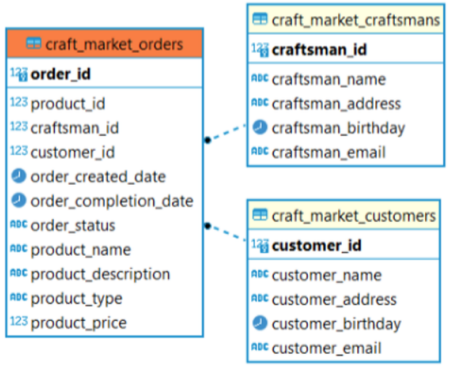
ИТМО

ETL-процесс

Задание 1. Модель данных



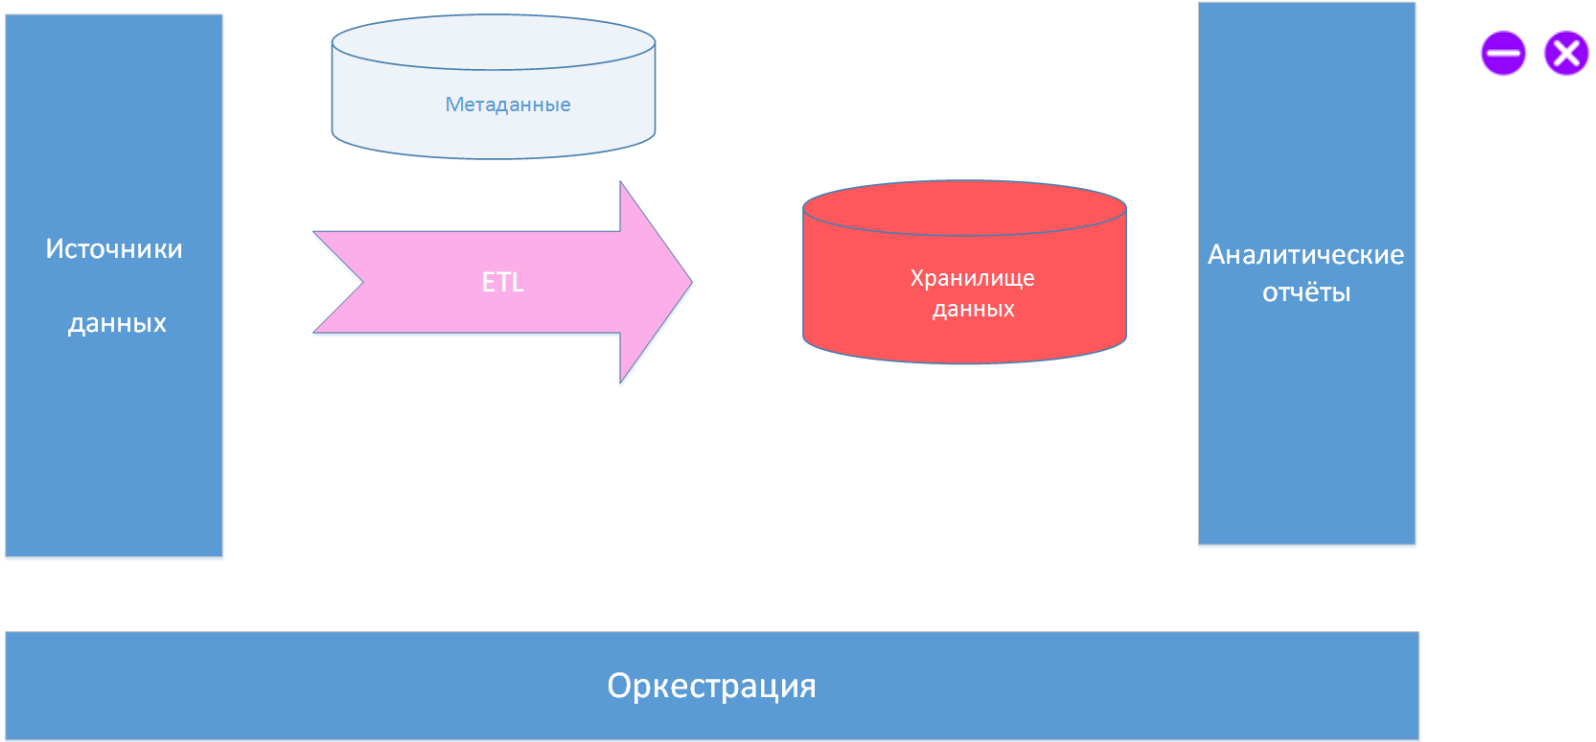




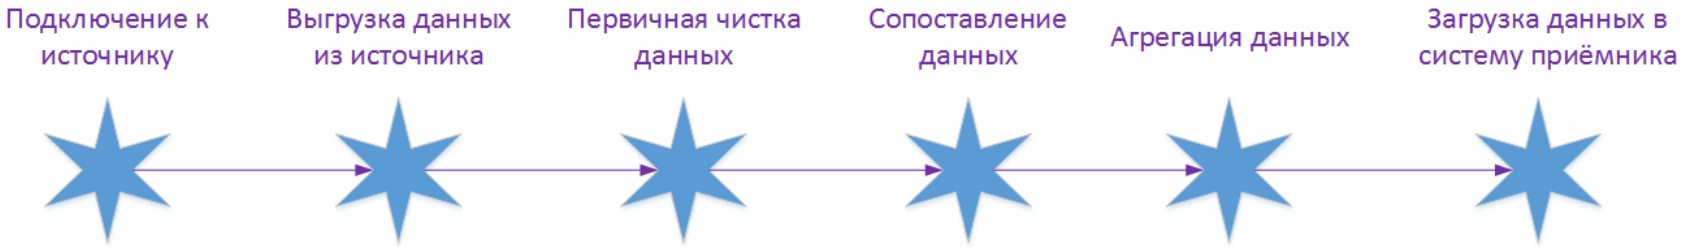
Напишите запрос

- идентификатор записи;
- идентификатор заказчика;
- Ф. И. О. заказчика;
- адрес заказчика;
- дата рождения заказчика;
- электронная почта заказчика;
- сумма, которую потратил заказчик;
- сумма, которую заработала платформа от покупок заказчика за месяц (10% от суммы, которую потратил заказчик);
- количество заказов у заказчика за месяц;
- средняя стоимость одного заказа у заказчика за месяц;
- медианное время в днях от момента создания заказа до его завершения за месяц;
- самая популярная категория товаров у этого заказчика за месяц;
- идентификатор самого популярного мастера ручной работы у заказчика. Если заказчик сделал одинаковое количество заказов у нескольких мастеров, возьмите любого;
- количество созданных заказов за месяц;
- количество заказов в процессе изготовки за месяц;
- количество заказов в доставке за месяц;
- количество завершённых заказов за месяц;
- количество незавершённых заказов за месяц;
- отчётный период, год и месяц.

Архитектура



ETL-процесс


Подключение к источнику
Выгрузка данных из источника
Первичная чистка данных
Сопоставление данных
Агрегация данных
Загрузка данных в систему приёмника

ETL-процесс


Подключение к источнику
Выгрузка данных из источника
Первичная чистка данных
Сопоставление данных
Агрегация данных
Загрузка данных в систему приёмника
Подключение к источнику 1
Выгрузка данных из источника
Первичная чистка данных
Подключение к источнику 1
Выгрузка данных из источника
Первичная чистка данных

Агрегация данных

Заказы

Заказ_ид	Клиент_ид	Дата заказа
1	4	2024-10-01
2	6	2024-10-02

Клиенты

Заказ_ид	Клиент	Возраст
4	Mark	23
6	Inna	35

Возраст	Количество заказов
23	13
35	15

Загрузка данных

Полная загрузка	Инкрементальная загрузка
Эффективна, если данные за прошлые дни меняются — например, клиент возвращает товар.	Если данные меняются задним числом, то может потребоваться дополнительная перевыгрузка с изменением логики расчётов, иначе можно не увидеть события.
Поскольку загружается вся информация, затраты на предварительную обработку данных и маппинг будут минимальны.	Больше времени тратится на предобработку данных, потому что их нужно очищать каждую итерацию.
Нагрузка на производительность процесса из-за объёма передаваемых данных, записи и считывании информации в системах-источниках и приёмниках.	Нагрузка на системы-источники и приёмники контролируется шириной инкремента и частотой обновления.
Если данные изменились и произошло обновление витрины, то восстановить старые расчёты невозможно. Изменение того или иного показателя в бизнесе сложнее интерпретировать.	Данные с прошлых загрузок не удаляются, поэтому все расчёты сохраняются. Изменение показателей легче интерпретировать.

Требования к ETL-процессу

Заказчики бывают двух типов :

- Бизнес
- Технические

Источники данных

Виды источников:

- OLAP
- OLTP
- API
- Файловое хранилище

Источники данных

1. Раз в пять минут действия пользователя сохраняются в файлы, которые раскладываются в папки по дням. Путь до файлов лежит в формате с JSON. В пайплайне настроен ежедневный сбор всех данных из папки за вчерашний день, подсчёт количества посещений уникальных пользователей и обновление витрины.

2. Каждый заказ пользователя фиксируется приложением и сохраняется в виде строчки в таблицу «Заказы» , в которой определён формат и набор параметров. В пайплайне настроен просмотр динамики количества заказов и среднего количества заказов на клиента за каждый час и сохранение новых инкрементов в витрине.

3. В компании используется внешняя облачная система, в которой бронируются даты доставки. Прямого доступа к данным этого сервиса нет. Каждые пять минут в пайплайне собирается информация о новых заказах и клиенте и сохраняется в систему для оперативной аналитики по задержке заказов.

Задание 2:

ИТМО

Пусть есть три файла:

user_order_log.csv
- id
- uniq_id
- date_time
- city_id
- city_name
- customer_id
- first_name
- last_name
- item_id
- item_name
- quantity
- payment_amount

user_activity_log.csv
- Id
- uniq_id
- date_time
- action_id
- customer_id
- quantity

customer_research.csv
- date_id
- category_id
- geo_id
- sales_qty
- sales_amt

Таблица customer_research:
- поле Date_id
- поле Geo_id
- поле Sales_qty
- поле Sales_amt

Таблица user_activity_log:
- поле Date_time
- поле Customer_id

Таблица user_order_log:
- поле Date_time
- поле Customer_id
- поле Quantity
- поле Payment_amount

Автоматизация ETL

Что заносить в логи:

- время начала работы пайплайна,
- подключение к источнику,
- время начала загрузки данных в хранилище,
- уровень хранилища, в который загружается информация,
- название задачи и номер шага процесса загрузки, чтобы было легче найти ошибку, если пайплайнов будет много,
- как долго выполняется шаг,
- успешный или неуспешный статус шага,
- последнее успешное сообщение или описание ошибки.

Проверки данных

- количество загружаемых строк в хранилище,
- пропуски и аномалии в данных,
- важные метрики, например сумма оборота за предыдущий день,
- форматы загружаемых данных,
- изменение времени в датах, например сдвиг часового пояса.

Виды загрузок

- архивная
- полный пересчёт
- инкрементальная

Как разложить данные по готовым слоям