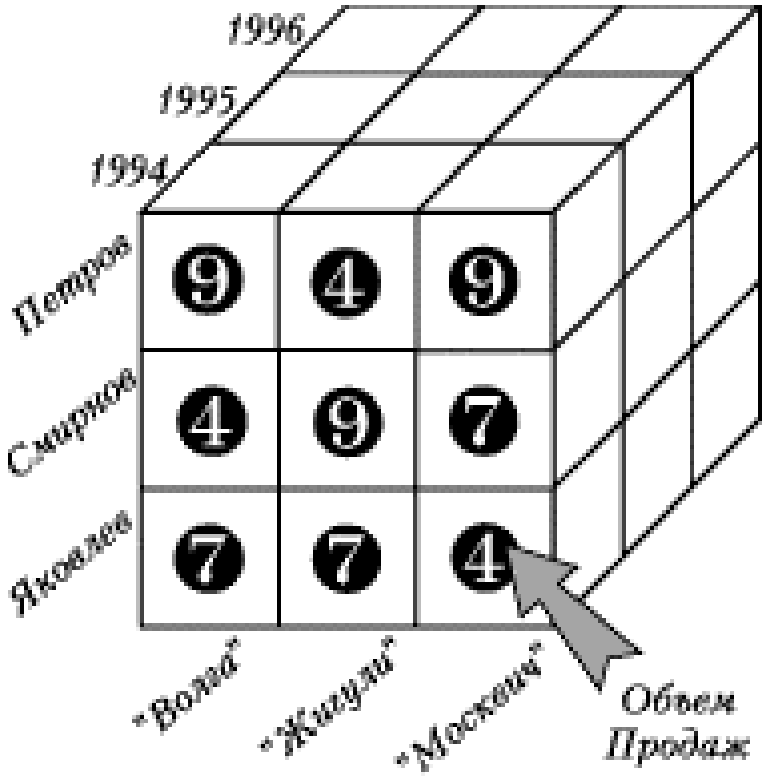
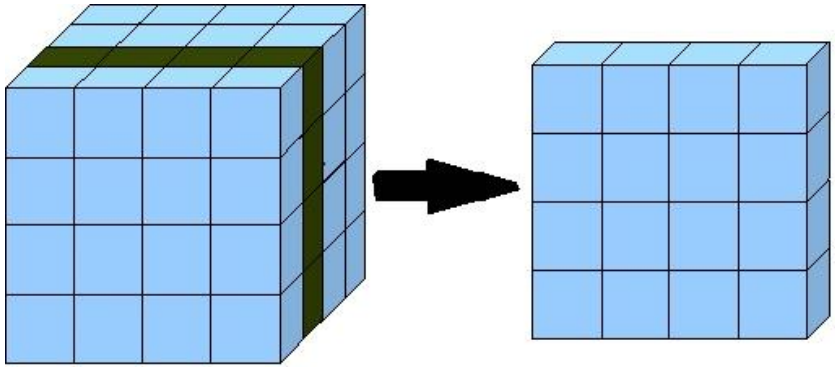
ИТМО

Кубы данных (многомерная модель данных)

Трехмерный куб



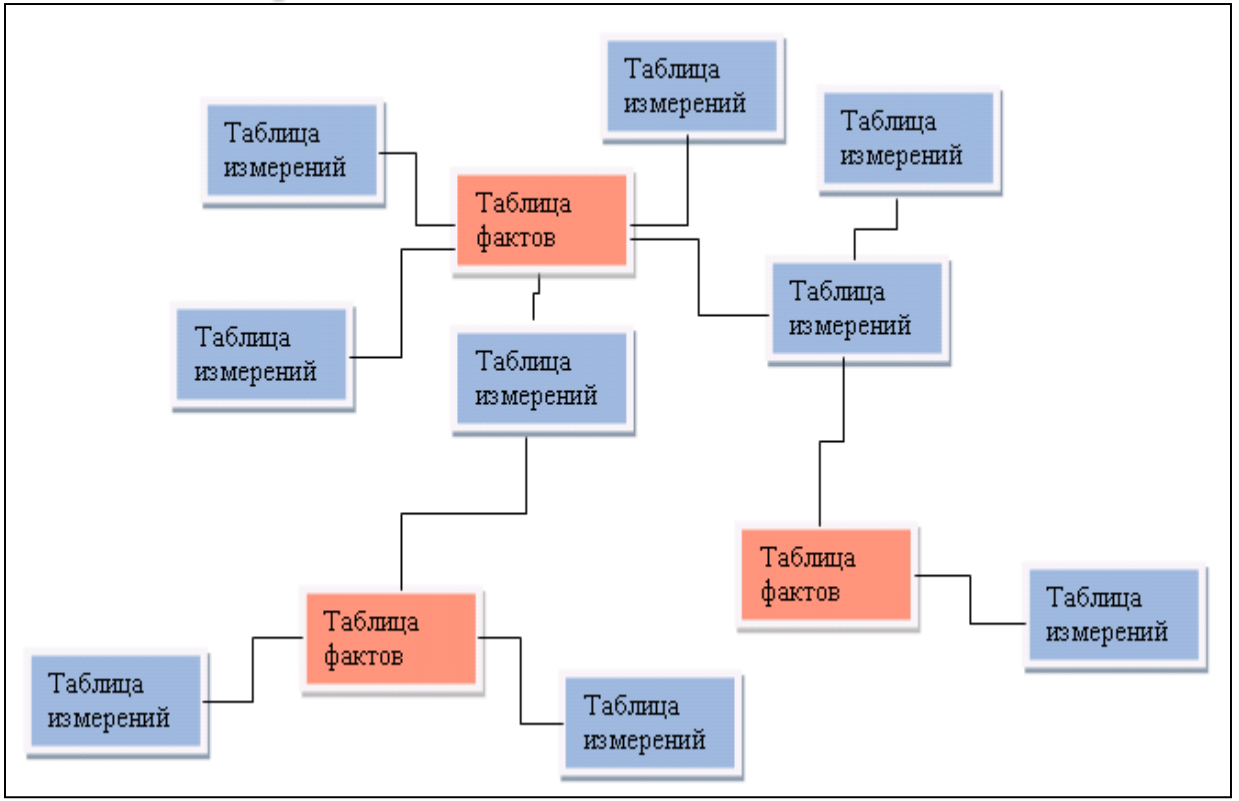
Показатель
Измерение (dimension)
Ячейка (cell)



Загрузка данных в куб

```
INSERT INTO SalesCube
    SELECT
        t.Year, t.Quarter, t.Month, t.Day,
        p.ProductID, p.Category, p.Price,
        r.RegionID, r.City, r.Country,
        SUM(s.SalesAmount) as SalesAmount
    FROM Sales s
    JOIN TimeDim t ON s.TimeID = t.TimeID
    JOIN ProductDim p ON s.ProductID = p.ProductID
    JOIN RegionDim r ON s.RegionID = r.RegionID
    GROUP BY
        t.Year, t.Quarter, t.Month, t.Day,
        p.ProductID, p.Category, p.Price,
        r.RegionID, r.City, r.Country;
```

Многомерный куб с несколькими таблицами фактов



Иерархии в измерениях

- ✓ сбалансированные (balanced);
- ✓ несбалансированные (unbalanced);
- ✓ неровные (balanced).

SDC – Slowly Changing Dimension

ИТМО

SCD 0 - Passive method (No change in data) - **Неизменное измерение**

SCD 1 – Overwriting the old value (Latest Record Only) - **Перезапись**

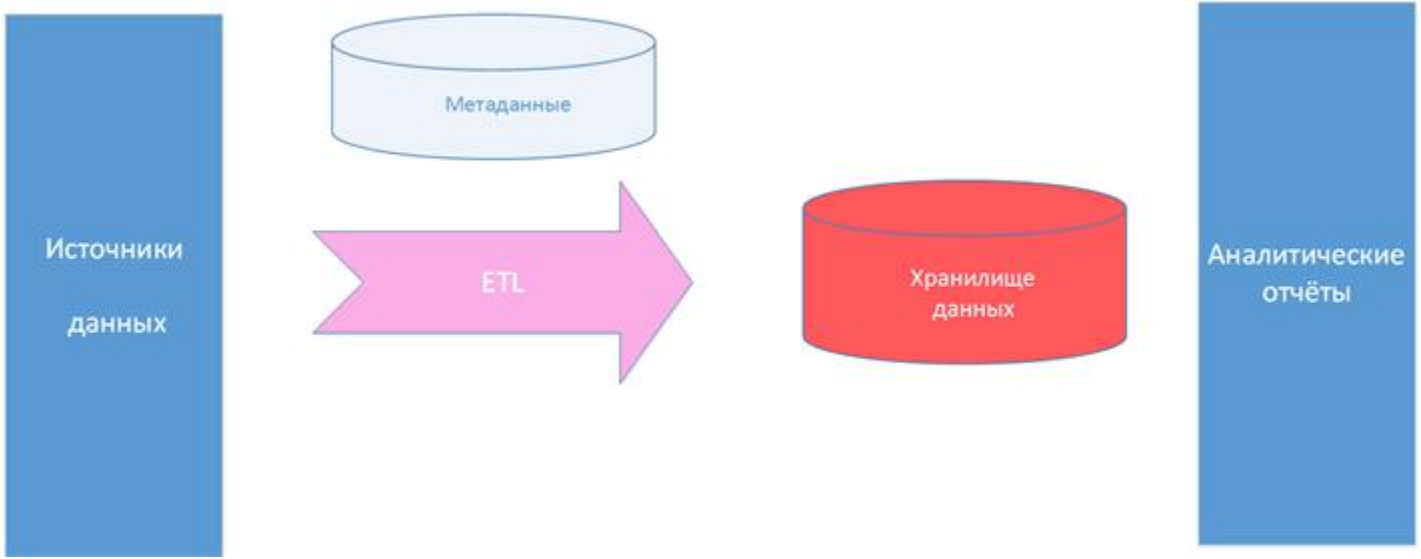
SCD 2 – Creating a new additional record (Maintains History) - **Добавление новой строки**

SCD 3 – Creating an additional Column (Rarely Used) - **Добавление нового атрибута**

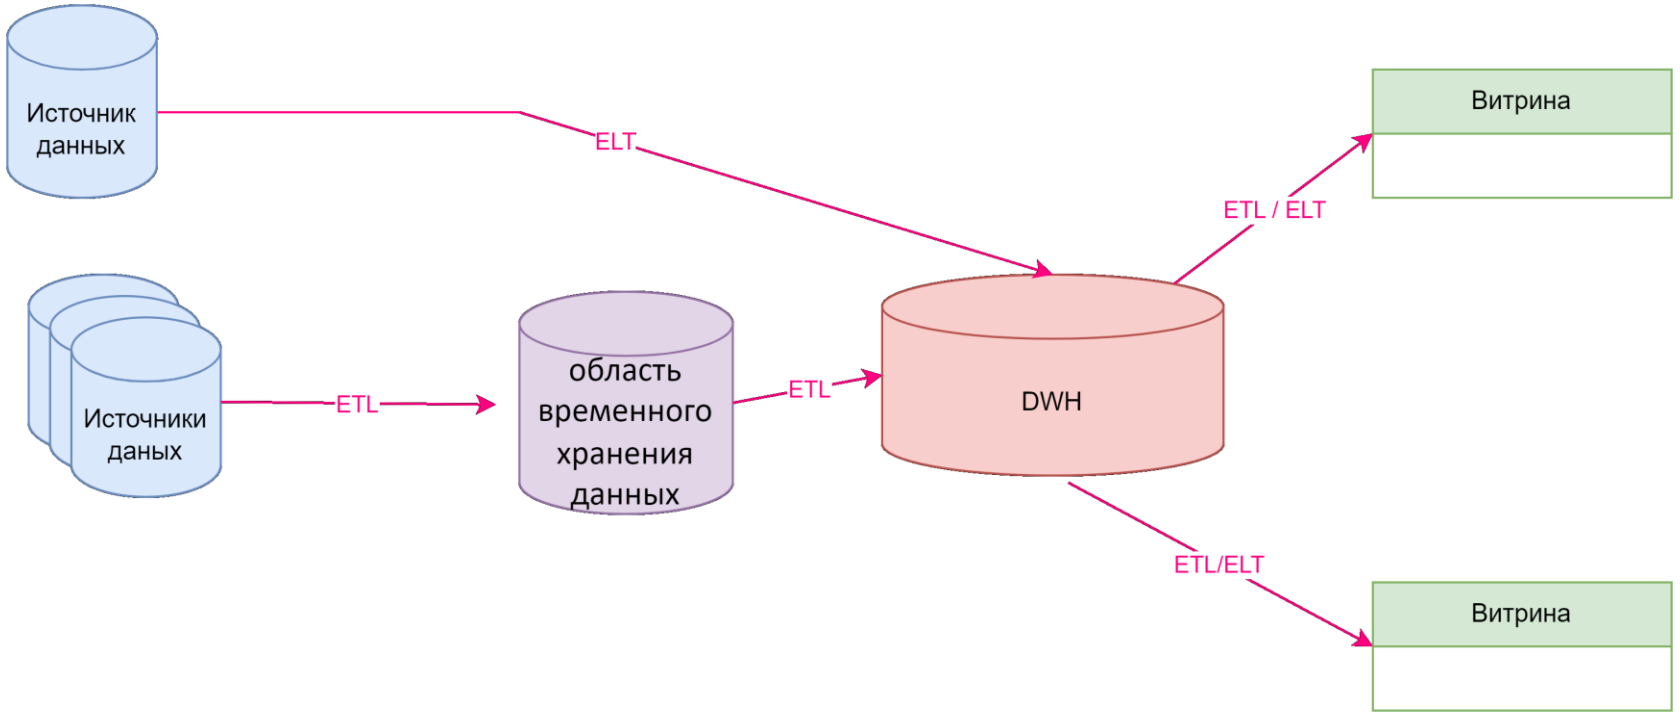
SCD 4 – Using history table SCD - **Таблица истории**

SCD 5, SCD 6 - The hybrid approach **Комбинированный подход**

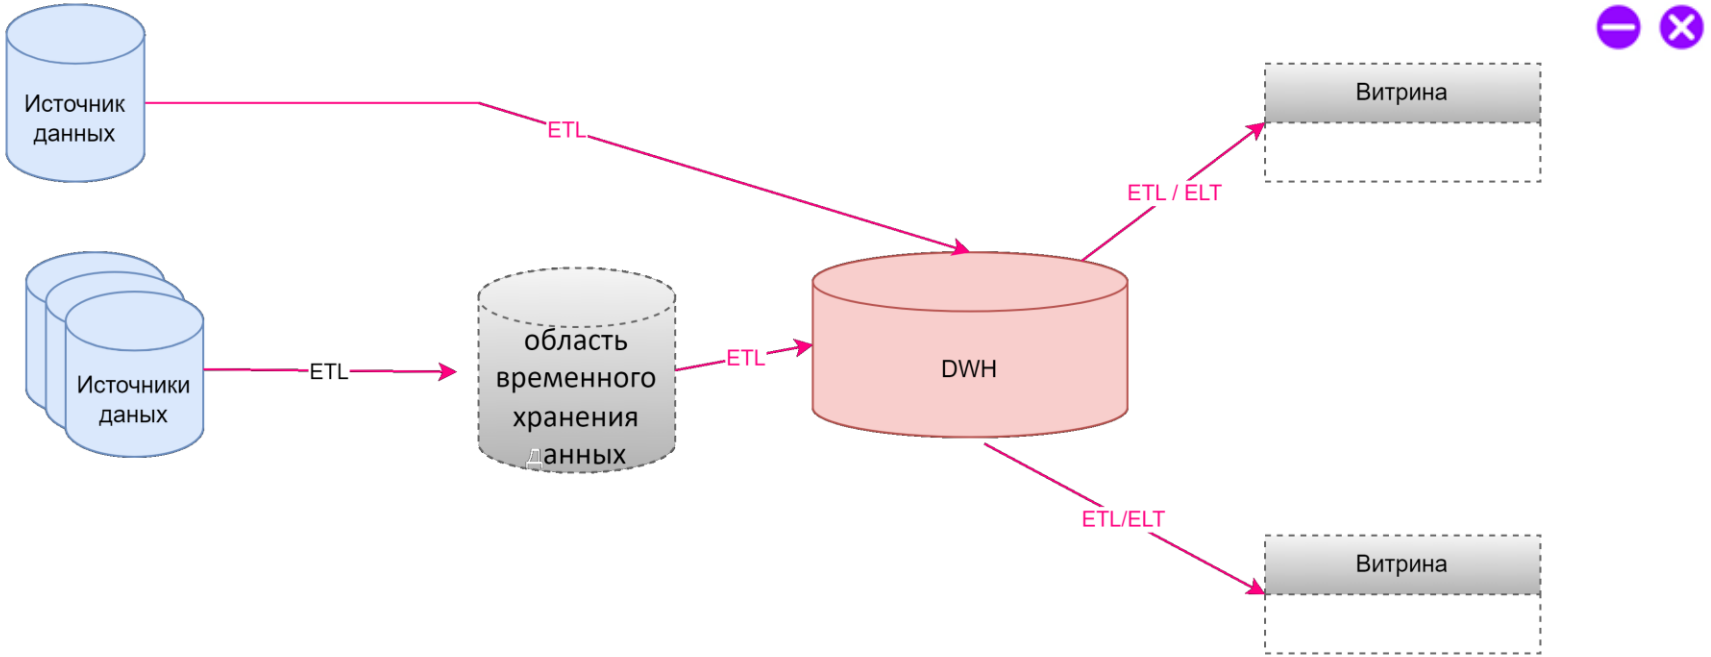
Архитектура



Модель Инмона



Модель Кимбалла



Витрины данных

Виды витрин

Статичные

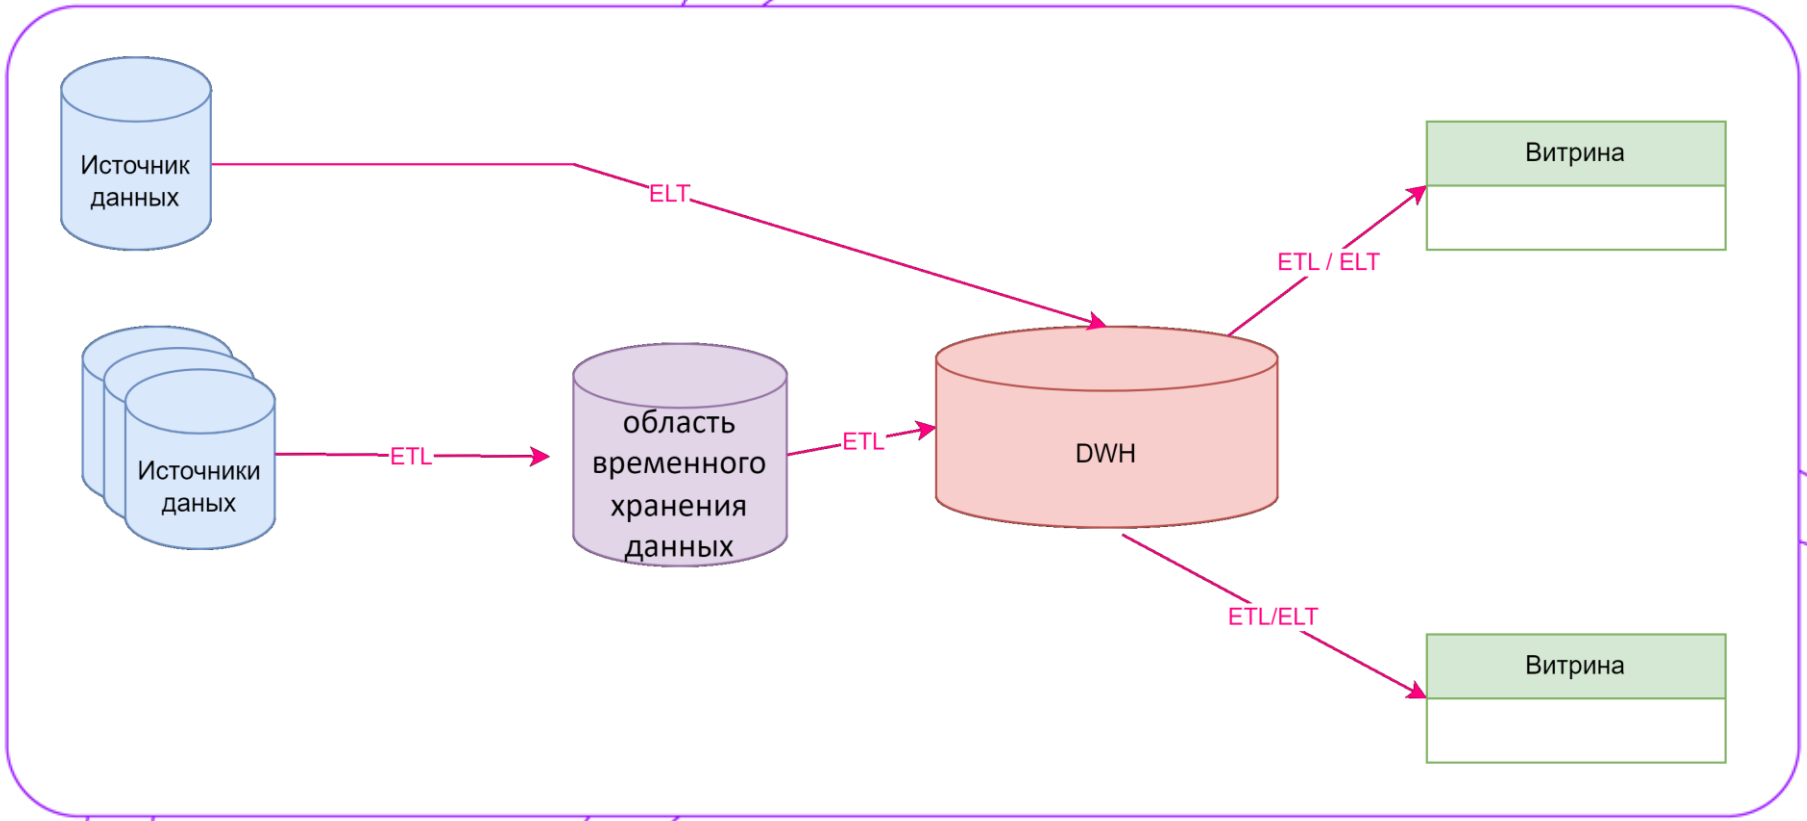
- Таблицы
- Материализованные представления

Динамичные

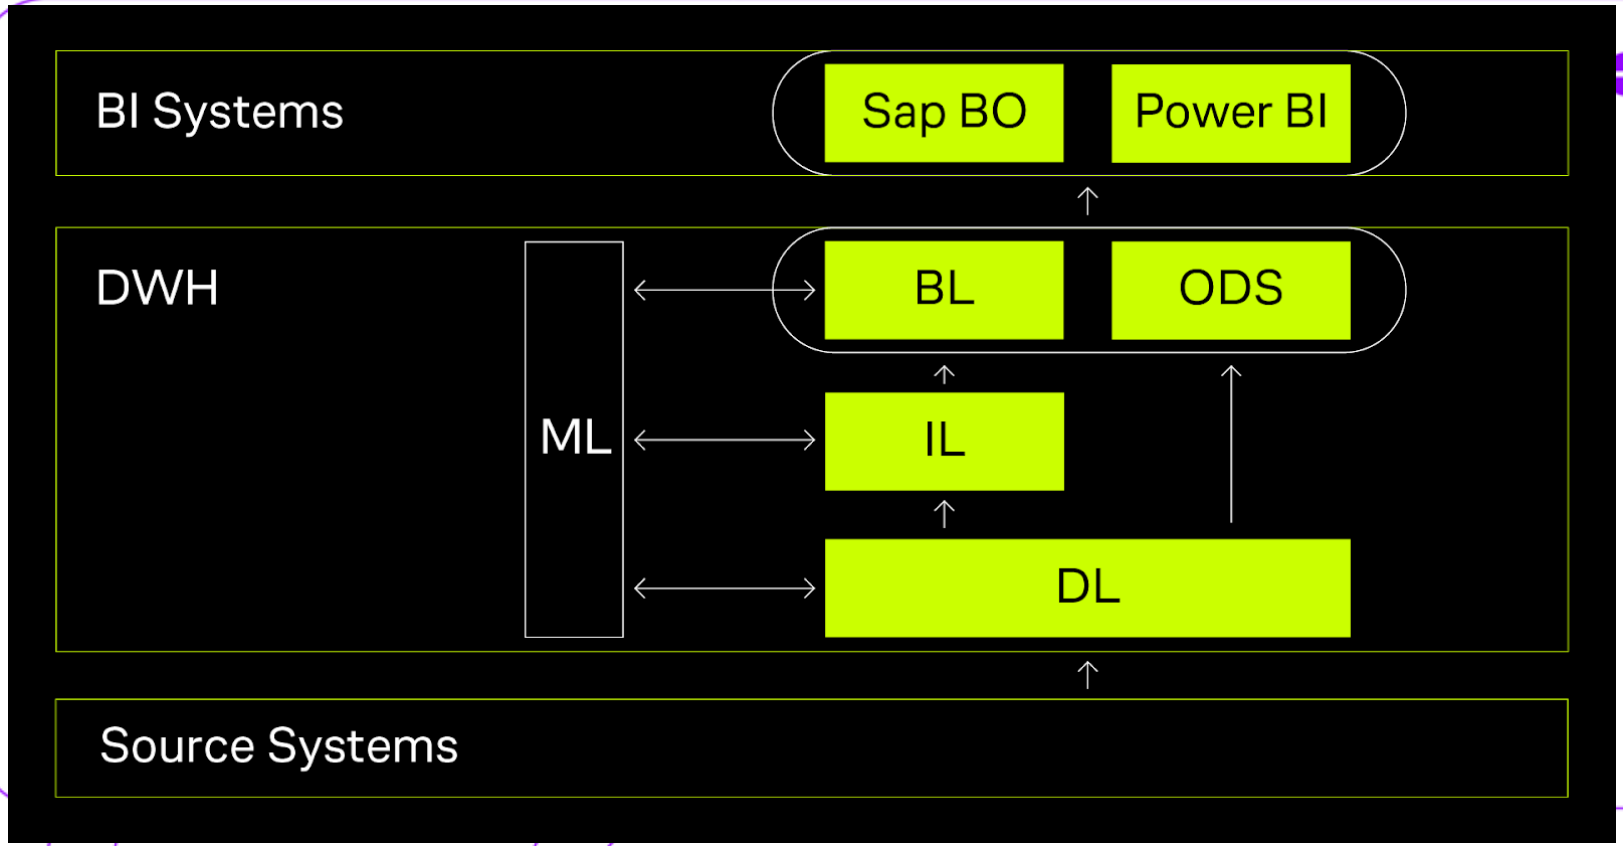
- Представления
- Таблицы, которые требуют периодического обновления

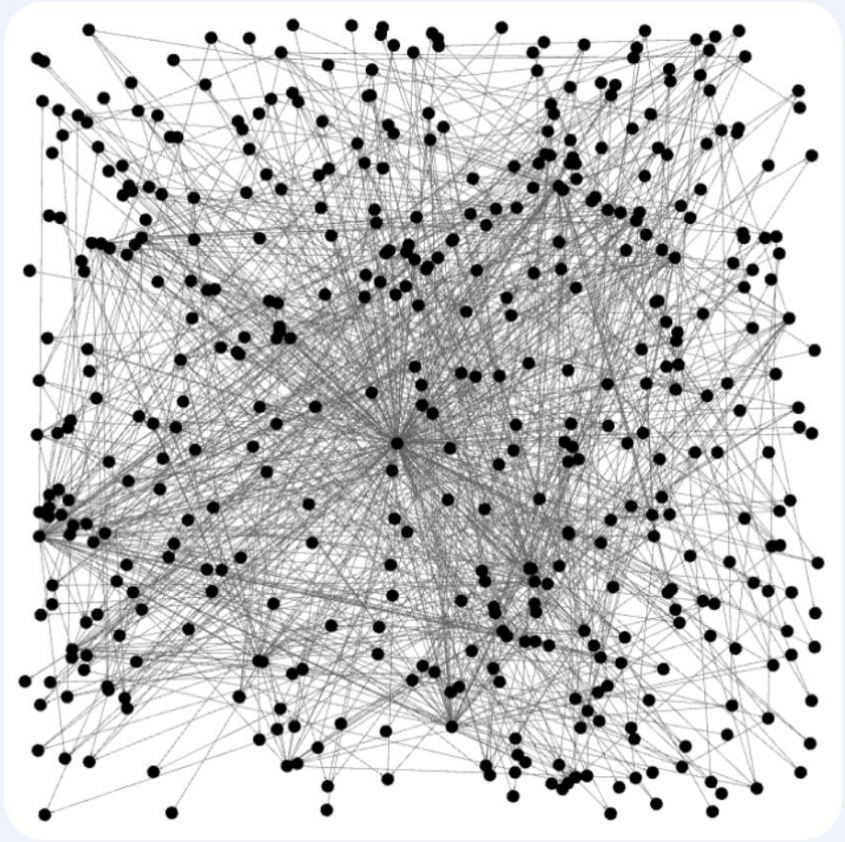
Витрина -> Витрина_в1_06052024 ->
-> Витрина_в0_06052024 ->
Обновлённая Витрина

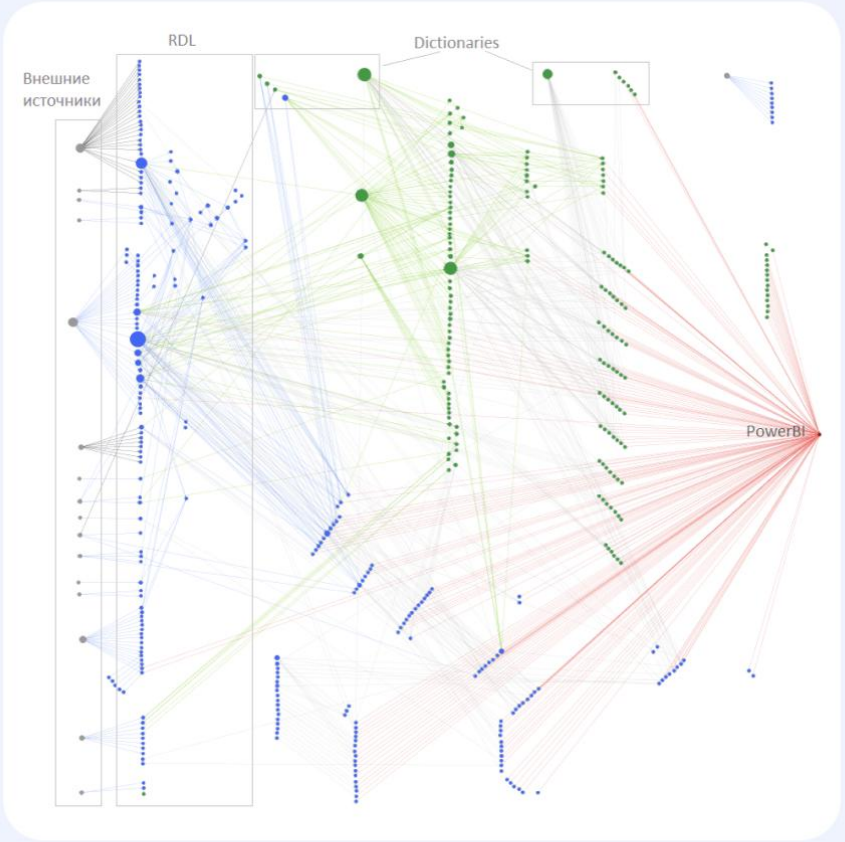
Как разложить данные по слоям



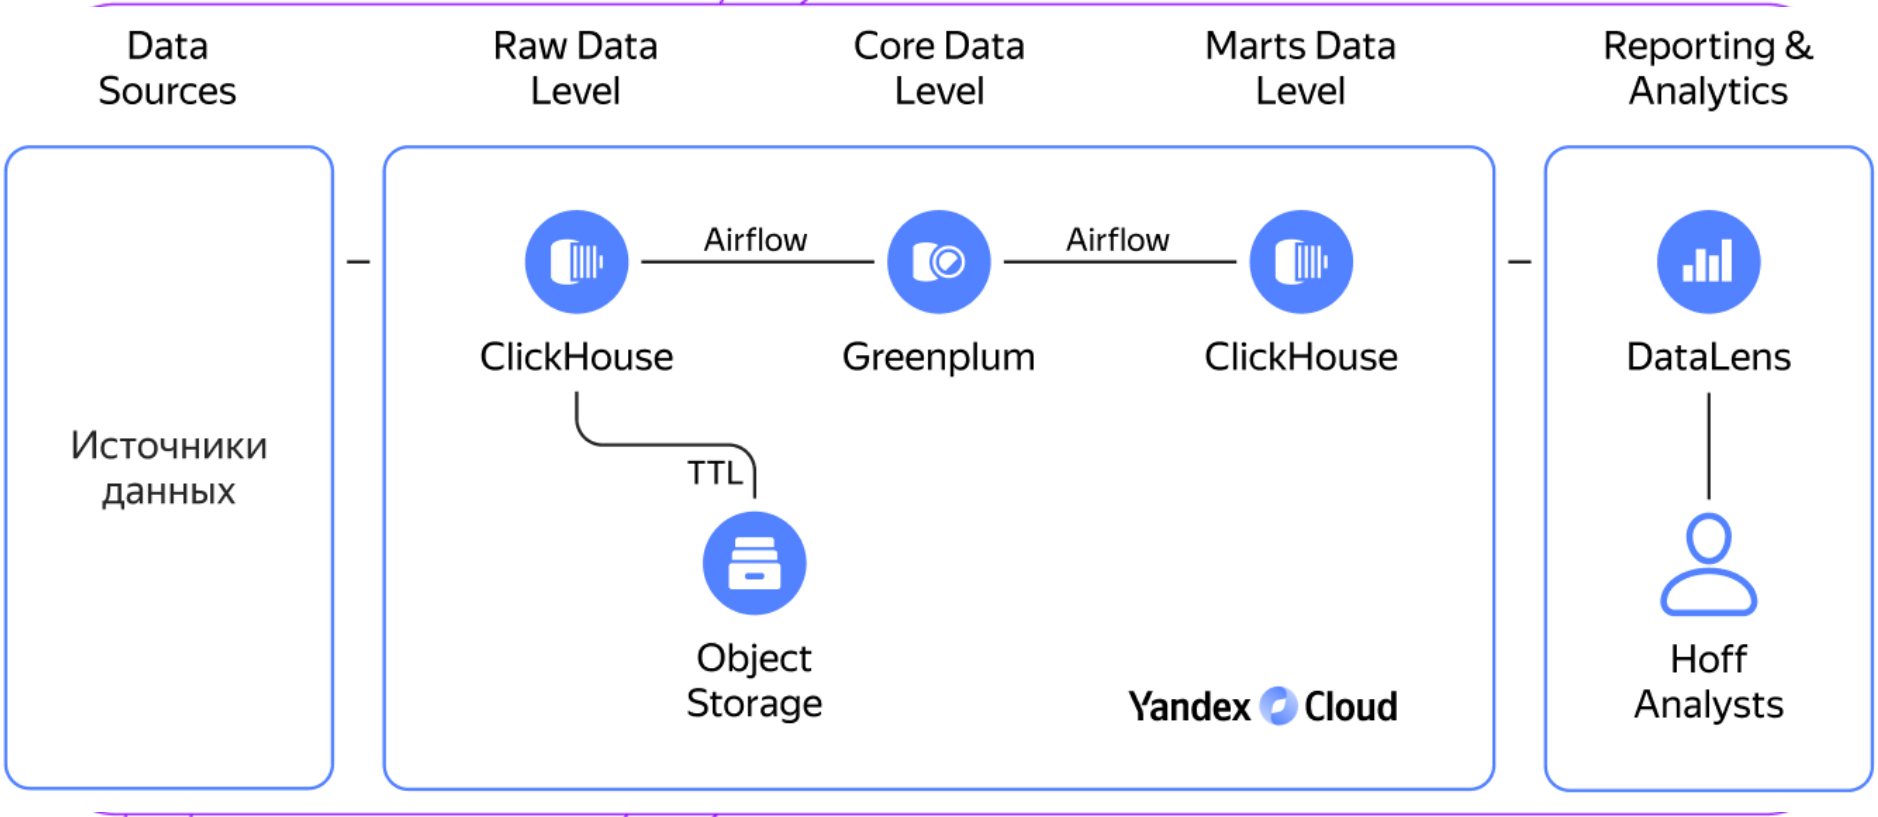
Lamoda DWH



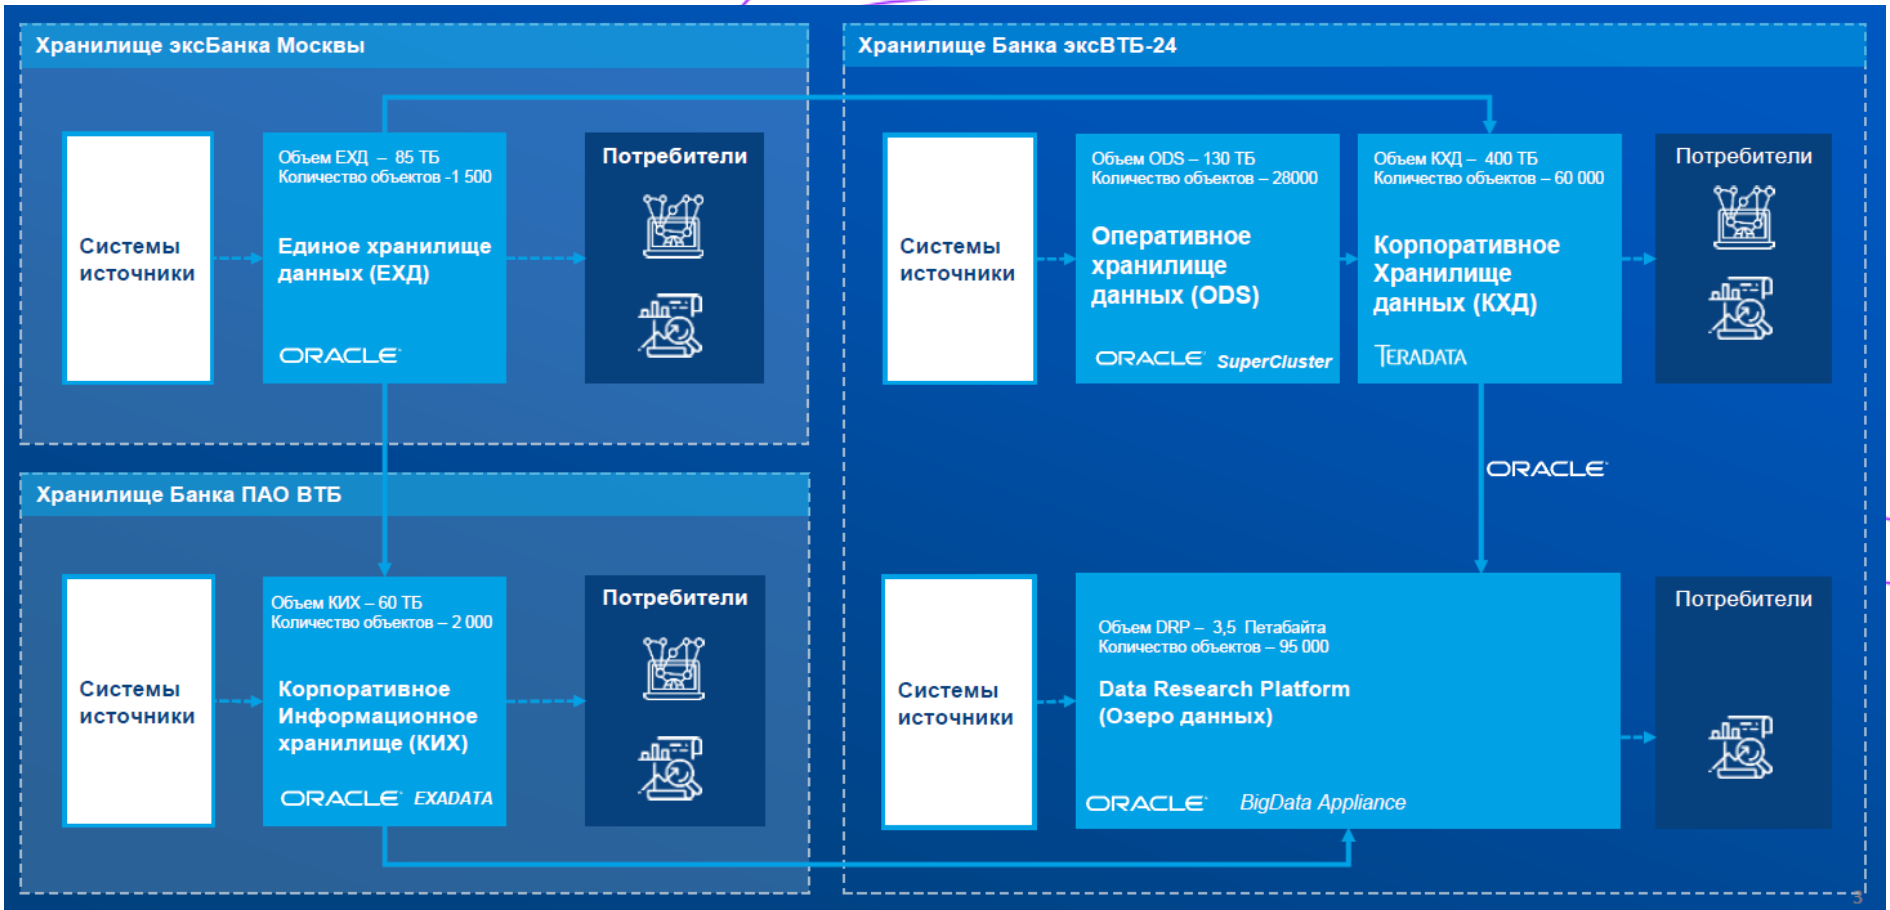



RDL
Dictionaries
Внешние
источники
PowerBI

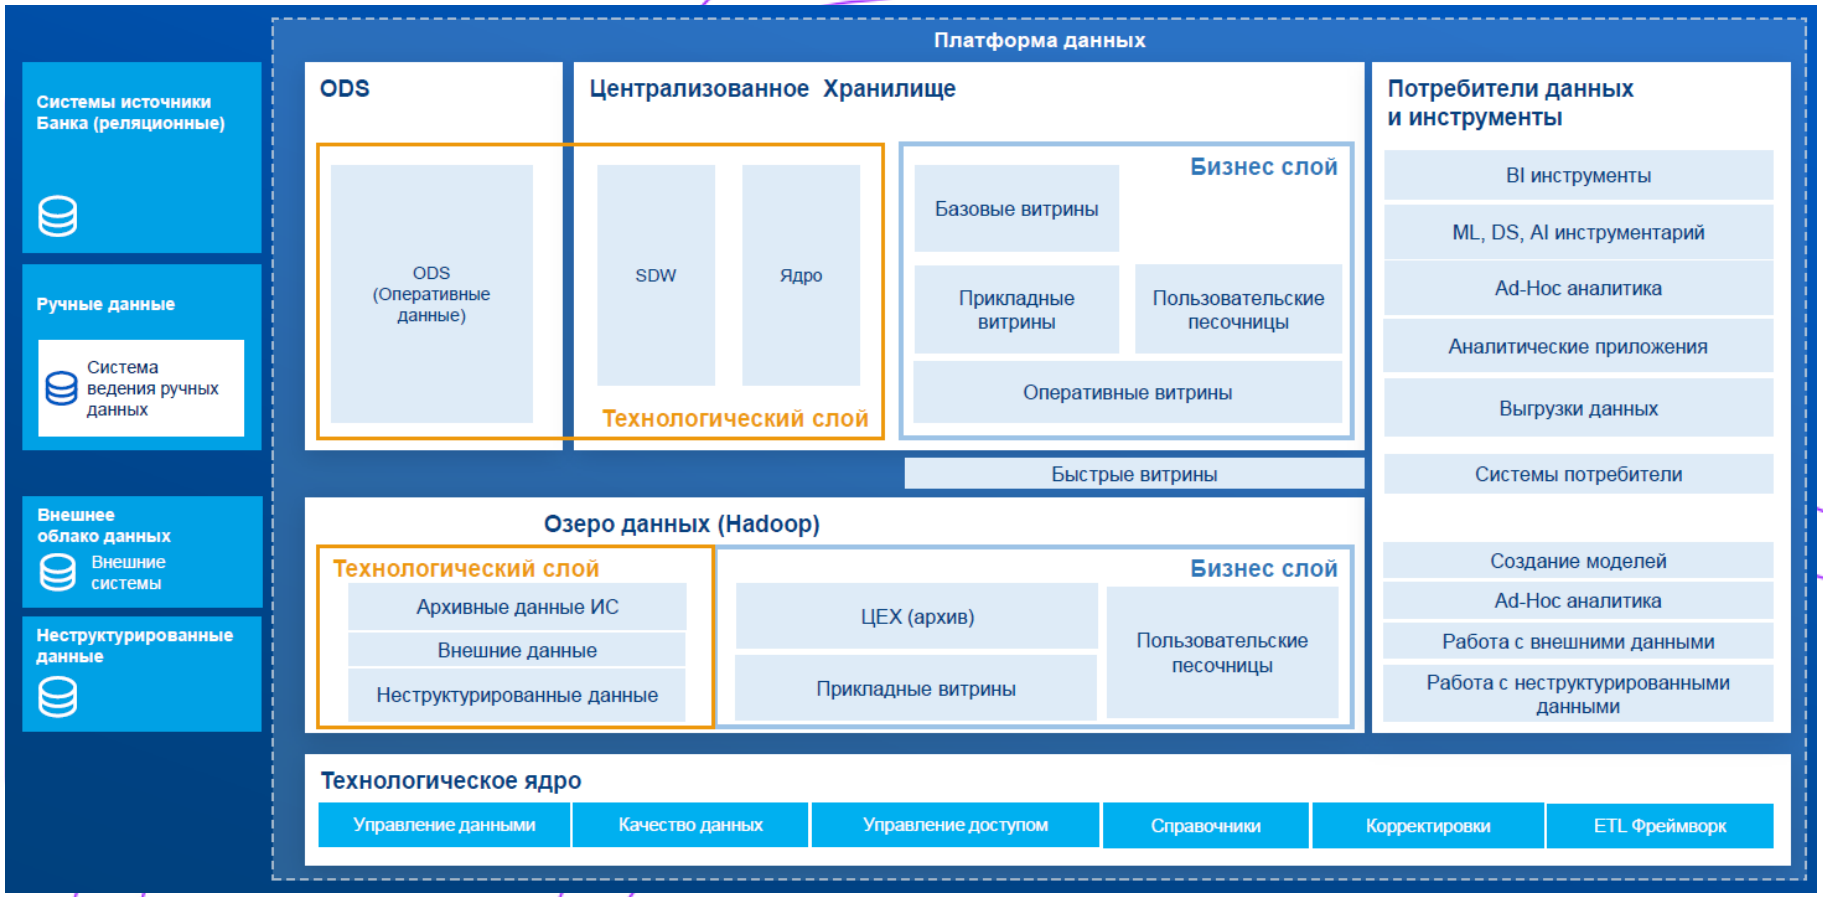
Hoff DWH


Data Sources
Raw Data Level
Core Data Level
Marts Data Level
Reporting & Analytics
Источники данных
Airflow
Airflow
ClickHouse
Greenplum
ClickHouse
TTL
Object Storage
Yandex Cloud
DataLens
Hoff Analysts

ВТБ


Хранилище эксБанка Москвы
Системы источники
Объем ЕХД – 85 ТБ
Количество объектов -1 500
Единое хранилище данных (ЕХД)
ORACLE
Потребители
Хранилище Банка ПАО ВТБ
Системы источники
Объем КИХ – 60 ТБ
Количество объектов – 2 000
Корпоративное Информационное хранилище (КИХ)
ORACLE EXADATA
Потребители
Хранилище Банка эксВТБ-24
Системы источники
Объем ODS – 130 ТБ
Количество объектов – 28000
Оперативное хранилище данных (ODS)
ORACLE SuperCluster
Объем КХД – 400 ТБ
Количество объектов – 60 000
Корпоративное Хранилище данных (КХД)
TERADATA
Потребители
ORACLE
Системы источники
Объем DRP – 3,5 Петабайта
Количество объектов – 95 000
Data Research Platform (Озеро данных)
ORACLE BigData Appliance
Потребители

VTB DWH


Системы источники Банка (реляционные)
Ручные данные
Система ведения ручных данных
Внешнее облако данных
Внешние системы
Неструктурированные данные
Платформа данных
ODS
ODS (Оперативные данные)
Централизованное Хранилище
SDW
Ядро
Технологический слой
Бизнес слой
Базовые витрины
Прикладные витрины
Пользовательские песочницы
Оперативные витрины
Быстрые витрины
Потребители данных и инструменты
BI инструменты
ML, DS, AI инструментарий
Ad-Hoc аналитика
Аналитические приложения
Выгрузки данных
Системы потребители
Озеро данных (Hadoop)
Технологический слой
Архивные данные ИС
Внешние данные
Неструктурированные данные
Бизнес слой
ЦЕХ (архив)
Прикладные витрины
Пользовательские песочницы
Создание моделей
Ad-Hoc аналитика
Работа с внешними данными
Работа с неструктурированными данными
Технологическое ядро
Управление данными
Качество данных
Управление доступом
Справочники
Корректировки
ETL Фреймворк

Проектирование ETL

Порядок загрузки объектов

- Измерения
- Факты

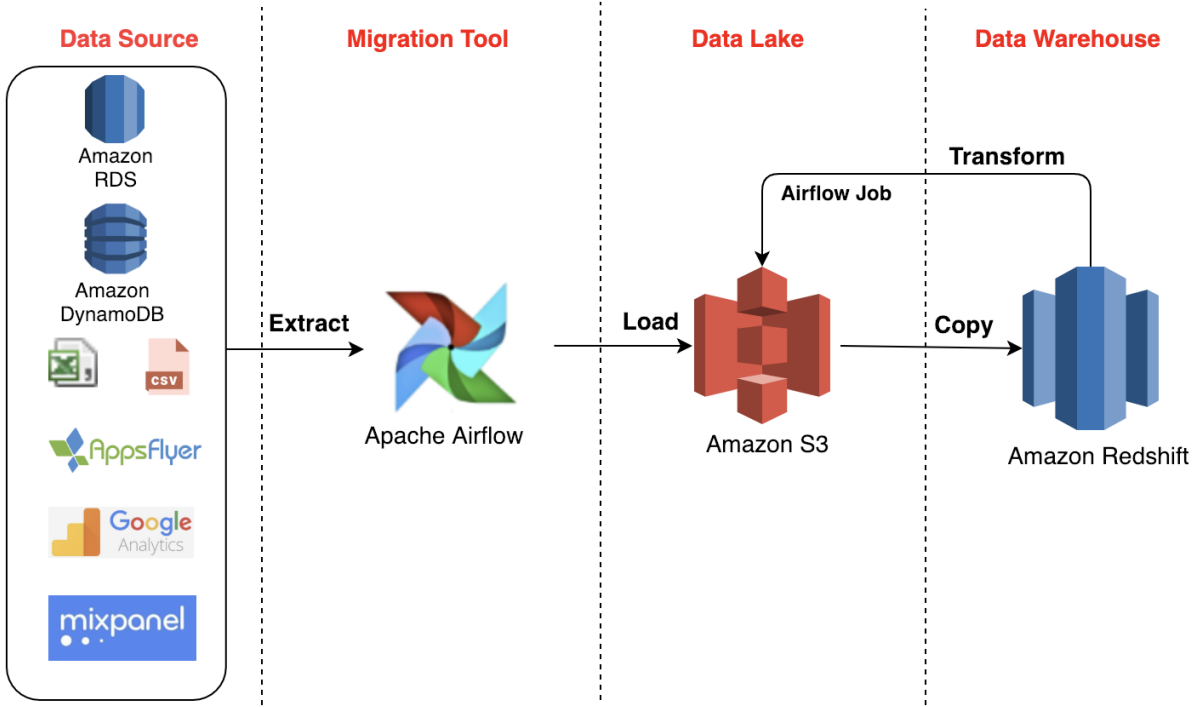
Восстановление данных

Архитектура



https://m.fotostrana.ru/public/post/233685/1851575716/

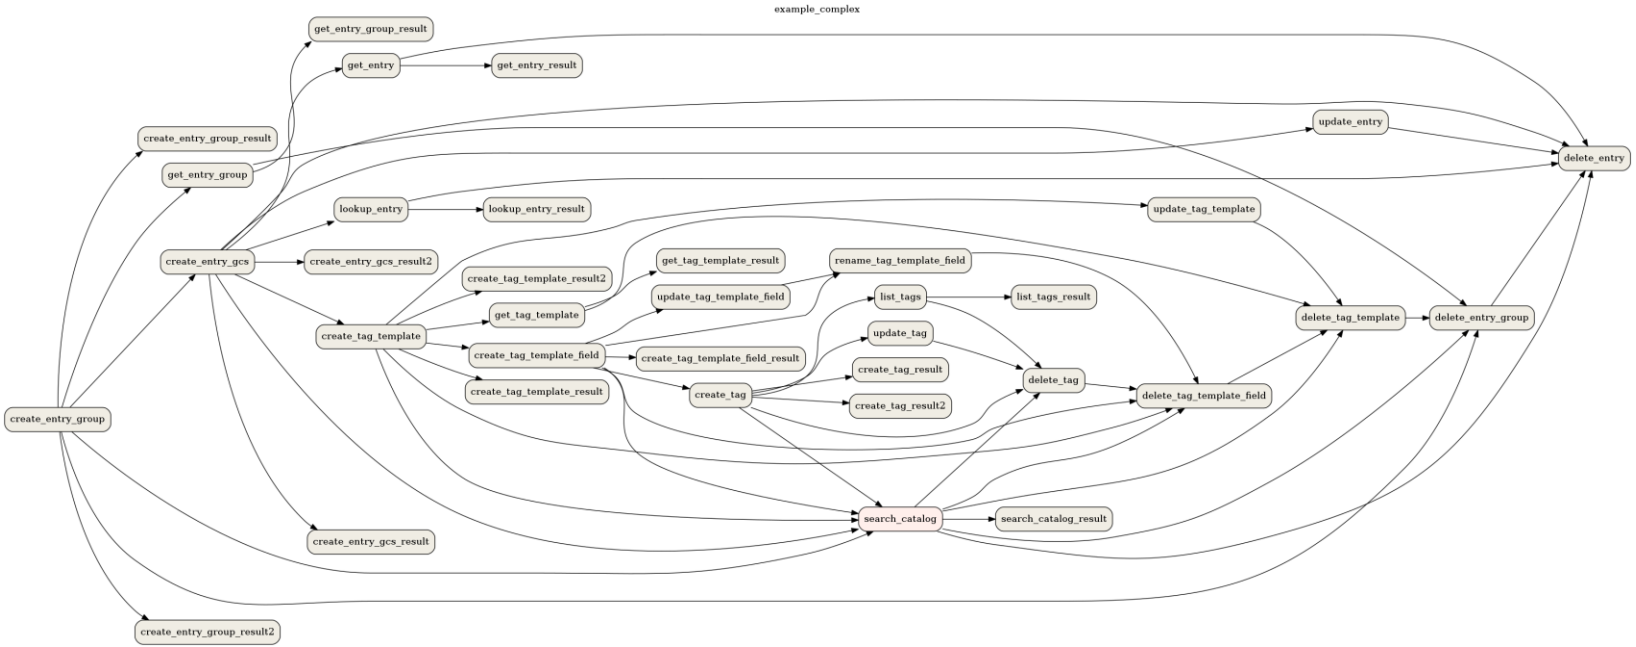
Организация процессов обработки с Airflow



https://habr.com/ru/articles/512386/

Основные понятия Airflow

DAG (Directed Acyclic Graph)

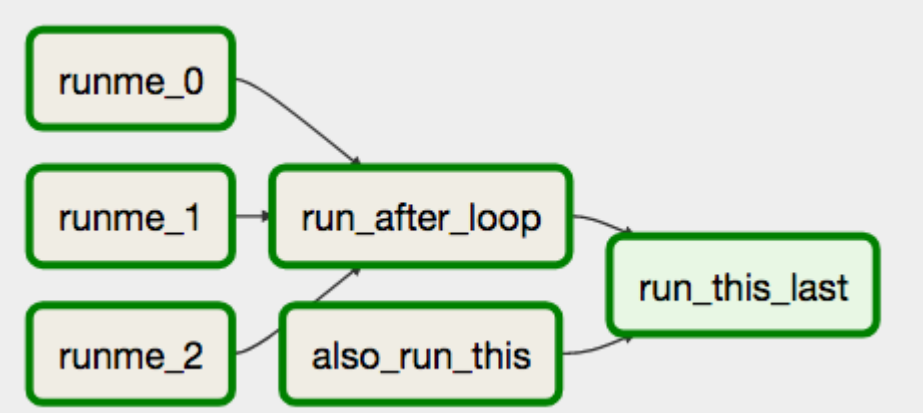


https://imghub.ru/airflow-example

Основные понятия Airflow

ИТМО

Задачи (Tasks)



TriggerDagRunOperator и ExternalTaskSensor.

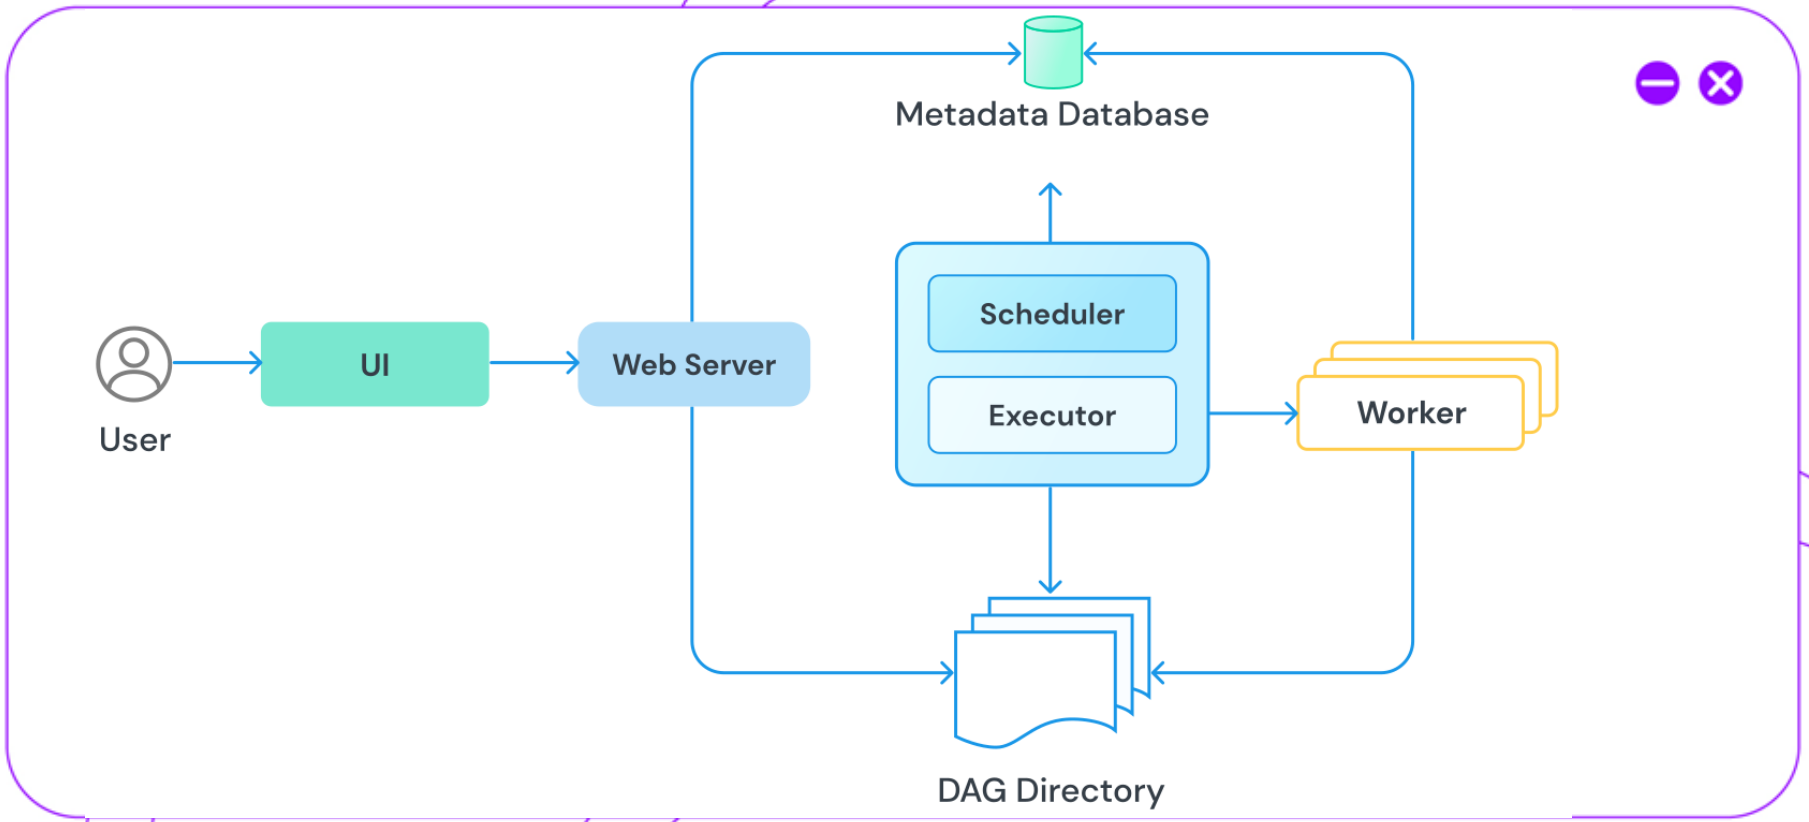
https://imghub.ru/airflow-example

Основные понятия Airflow

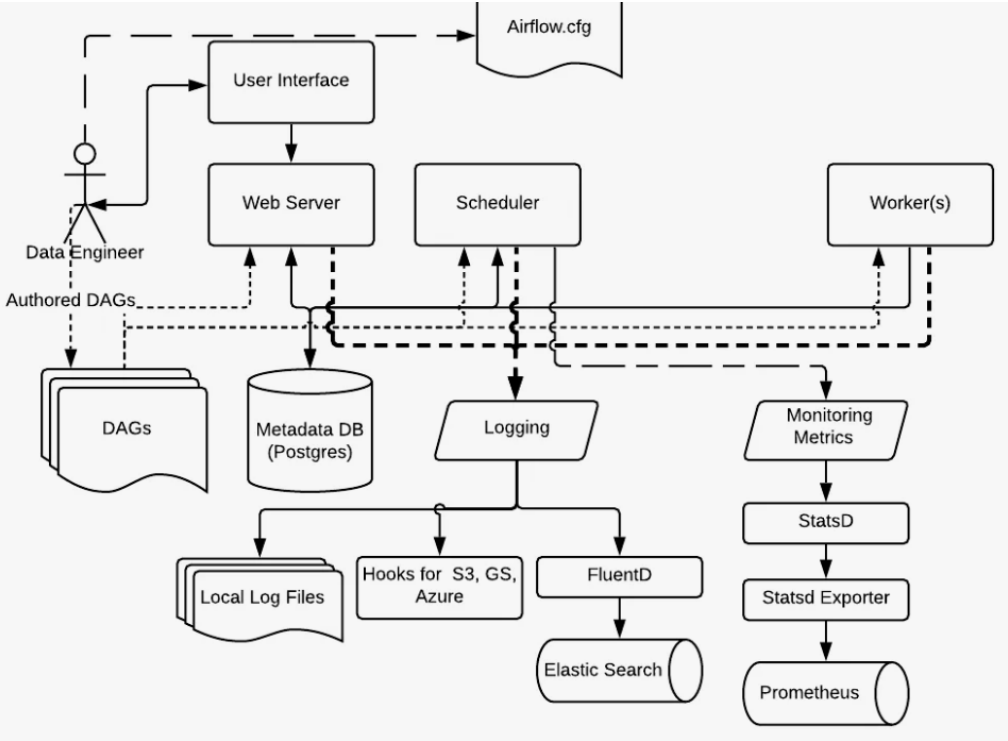
- DAG
- Задача
- Оператор
- Сенсор

https://airflow.apache.org/docs/apache-airflow.html

Архитектура Airflow

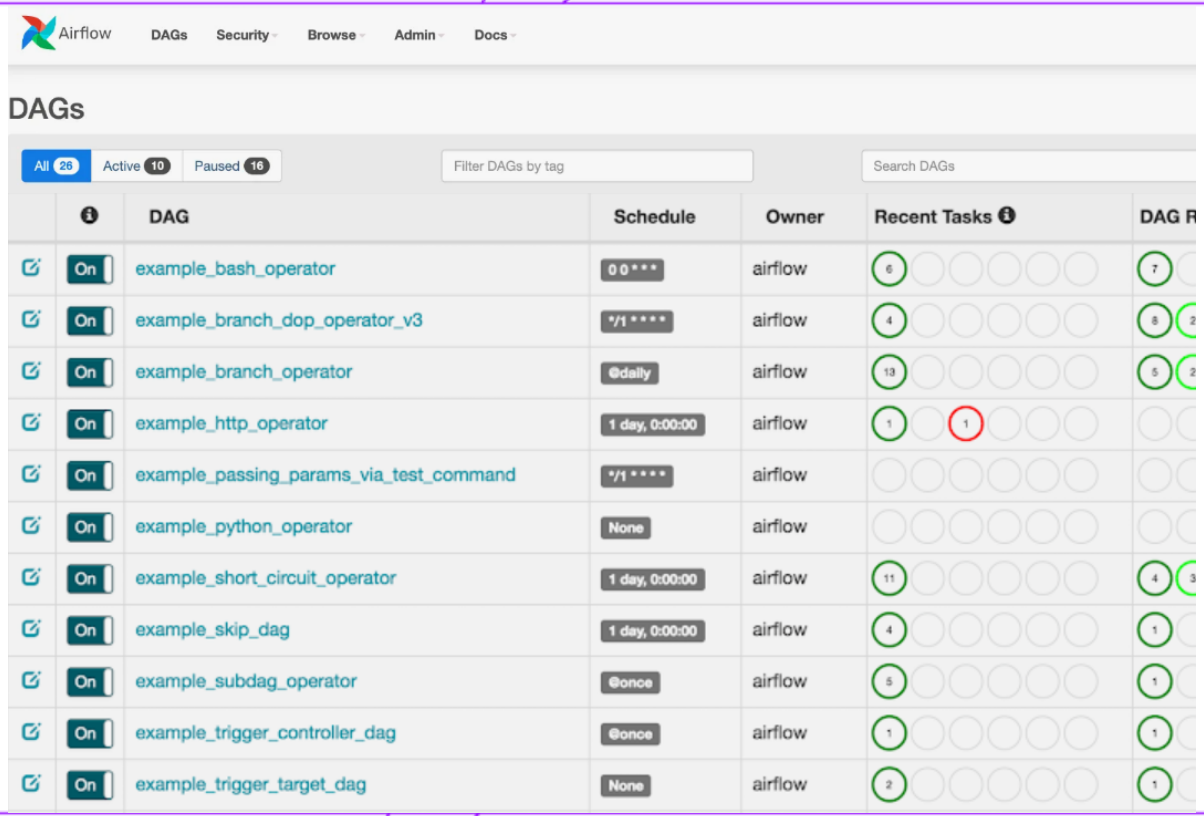


Архитектура Airflow



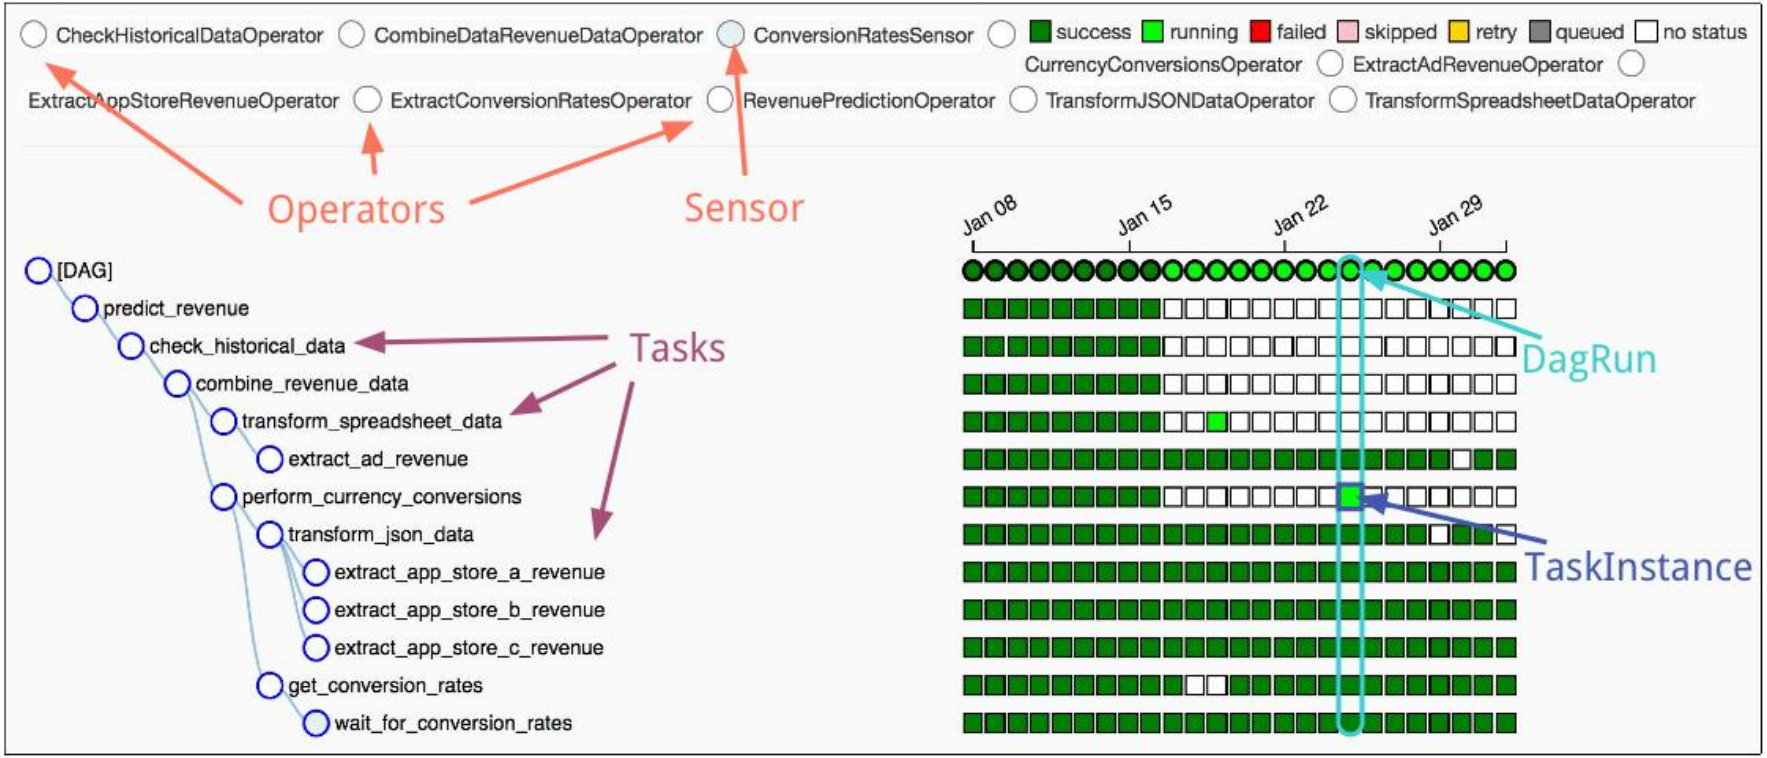
https://airflow.apache.org/docs/apache-airflow/2.2.2/logging-monitoring/logging-architecture.html

Как выглядит Airflow



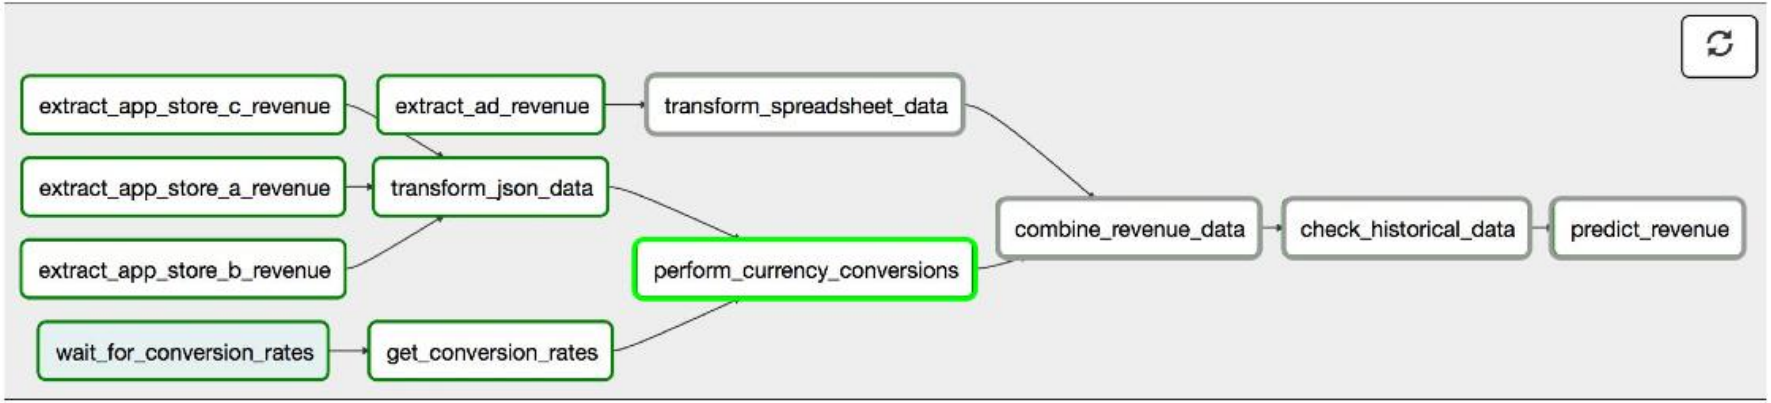
https://imghub.ru/airflow-example

Tree View - DAG



https://imghub.ru/airflow-example

Graph View - DAG



https://imghub.ru/airflow-example

Graph View - DAG

```
connection_list = lv.get('connection_list')

export_profiles_sql = '''
SELECT
  id,
  user_id,
  nickname,
  gender,
  {{params.shard_id}} as shard_id
FROM profiles
'''
```

Extract

DAG




```
for conn_id in connection_list:
    export_profiles = SqlToHiveViaHdfsTransfer(
        task_id='export_profiles_from_' + conn_id,
        sql=export_profiles_sql,
        hive_table='stg.profiles',
        overwrite=False,
        tmpdir='/data/tmp',
        conn_id=conn_id,
        params={'shard_id': conn_id[-1:], },
        compress=None,
        dag=dag
    )
```

Transform



```
export_profiles.set_upstream(exec_truncate_stg)
export_profiles.set_downstream(load_profiles)
```

Load

https://imghub.ru/airflow-example

Структура кода DAG

Секция импортов

```
from airflow import DAG
from airflow.operators.bash import BashOperator
from airflow.utils.dates import days_ago

from datetime import datetime, timedelta
from airflow import DAG
from airflow.operators.bash import BashOperator
from airflow.utils.dates import days_ago
```

Объявление dict с настройками операторов по умолчанию

```
default_args = {
'owner': 'romank',
'start_date': days_ago(0),
'depends_on_past': False,
}
```

https://bigdataschool.ru/blog/apache-airflow-quick-start.html

Структура кода DAG

Объявление DAG и операторов

```
with DAG(
   'mydag',
   default_args=default_args,
   schedule_interval='@once',
   catchup=False
) as dag:

   t1 = BashOperator(
      task_id='echo_hi',
      bash_command='echo "Hello"',
   )

   t2 = BashOperator(
      task_id='print_date',
      bash_command='date',
   )
```

Задание последовательности

```
   t1 >> t2
```

Объявление DAG и операторов

```
dag = DAG(
   'mydag',
   default_args=default_args,
   schedule_interval='@once',
   catchup=False
)

   t1 = BashOperator(
      task_id='echo_hi',
      bash_command='echo "Hello"',
   )

   t2 = BashOperator(
      task_id='print_date',
      bash_command='date',
   )

   t1 >> t2
```

https://bigdataschool.ru/blog/apache-airflow-quick-start.html

Структура кода DAG

```
from airflow import DAG
from airflow.operators.bash import BashOperator
from datetime import datetime, timedelta

# 1. Параметрыпоумолчаниюдлязадач
default_args= {
        'owner': 'airflow',
        'start_date': datetime(2025,1,1),
        'retries': 2,
        'retry_delay': timedelta(minutes=5),
}
# 2. ИнициализацияDAG
with DAG('00_minimal_bash', schedule='@daily', catchup=False, default_args=default_args
) as dag:
# 3. Определениезадач
print_date= BashOperator(task_id='print_date', bash_command='date')
hello = BashOperator(task_id='hello', bash_command="echo 'Hello Airflow!'")
# 4. Зависимости
print_date>> hello
```

TaskFlowAPI

```
from airflow.decorators import dag, task
from datetime import datetime
@dag(schedule='@daily', start_date=datetime(2025, 1, 1), catchup=False, tags=['example'])
def etl_pipeline():
        @task
        def extract(): data = [1, 2, 3]
                return data
        @task
        def transform(data: list):
                processed = [x * 2 for x in data]
                return processed
        @task
        def load(processed: list):
                print(f"Processedresults: {processed}")
        extracted_data= extract()
        ---> transformed_data= transform(extracted_data)
        load(transformed_data)
etl_dag= etl_pipeline()
```

XCom —обмен данными

Основные методы

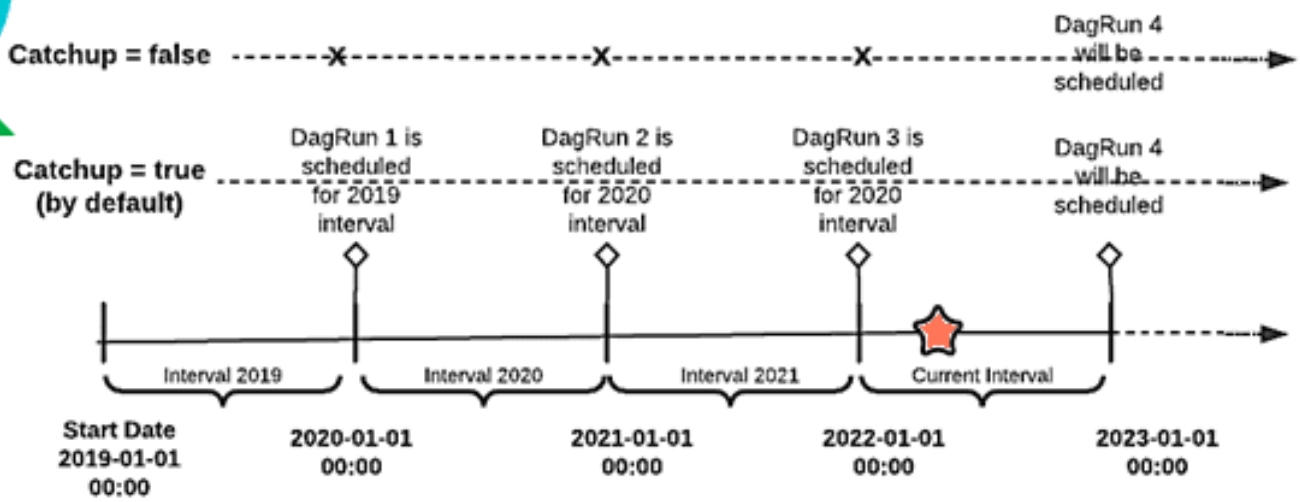
- ti.xcom_push(key, value)
- ti.xcom_pull(task_ids, key)
- Return
- TaskFlow API

Connections & Hooks

- **Connection**
- **Hooks**

```
from airflow.hooks.base import BaseHook
...
def task(**context):
conn = BaseHook.get_connection('conn_id')
secret = conn.password
pg_hook= PostgresHook(postgres_conn_id='analytics_db')
df= pg_hook.get_pandas_df('SELECT * FROM table;')
```

Время в Airflow



catchup=False,
schedule_interval=timedelta(minutes=5)

catchup=False,
schedule_interval='*/5 * * * *'

https://bigdataschool.ru/blog/dag-run-scheduling-in-airflow-some-features.html

Мониторинг и алерты

Состояния задач – основные статусы: *success*, *failed*, *running (желтый)*, *skipped*, *upstream_failed (не запущено из-за падения предка)*, *queued (ожидает ресурс)*.

Логи задач – проверяем вывод операторов *stdout/stderr*

Alerts – уведомления о событиях

email=['abc@abc.com'] и email_on_failure=True

SLA – в контексте Airflow SLA – это заданный порог времени, к которому задача должна закончиться.

sla=timedelta(hours=1)